Assistive*Vision* *

Sistema de identificación y localización espacial de objetos basado en visión por computador para asistencia a personas con discapacidad visual

Pasantía de investigación

Diomedes Farid Cerda Leon

Directora: Idanis Beatriz Diaz Bolaño
Codirector: Aquiles Alfonso Cohen Llanes

Introducción

Percepción del entorno *interior*



¿Qué hay delante?

Reconocer objetos y comunicar su posición mediante una descripción auditiva.

Interior · teléfono Android · voz local

Propósito de la investigación

Objetivo *general*

Desarrollar un sistema de asistencia implementado en un dispositivo móvil, basado en técnicas de visión artificial, para la identificación y localización espacial de objetos en entornos interiores orientado a apoyar la percepción del entorno en personas con discapacidad visual.

El propósito que articula la selección, el desarrollo y la evaluación.

Propuesta de pasantía, §4.1; informe final, introducción

Ruta de la investigación

Objetivos *específicos*

01 Seleccionar un modelo de detección de objetos optimizado para su implementación en dispositivos móviles con plataforma Android.

02 Desarrollar un prototipo funcional en plataforma Android que integre la cámara del dispositivo y un modelo de detección de objetos para identificar elementos del entorno y determinar su ubicación relativa, así como también descriptores de audio.

03 Evaluar el desempeño del prototipo en entornos interiores controlados, analizando métricas como precisión de detección, latencia de procesamiento y claridad de la retroalimentación auditiva.

Propuesta de pasantía, §4.2; informe final, introducción

Metodología de la propuesta

Tres fases de la *investigación*

Fase 1 · Revisión de literatura y diseño conceptual de la arquitectura

Objetivo 1: selección del modelo. Requerimientos y comparación de seis configuraciones con 80 imágenes y 257 anotaciones.

Fase 2 · Desarrollo de la arquitectura

Objetivo 2: prototipo Android. Integración de captura, detección, localización relativa y descriptores de audio.

Fase 3 · Evaluación

Objetivo 3: desempeño del sistema. 198 fotografías y 889 anotaciones para analizar detección, procesamiento y salida auditiva.

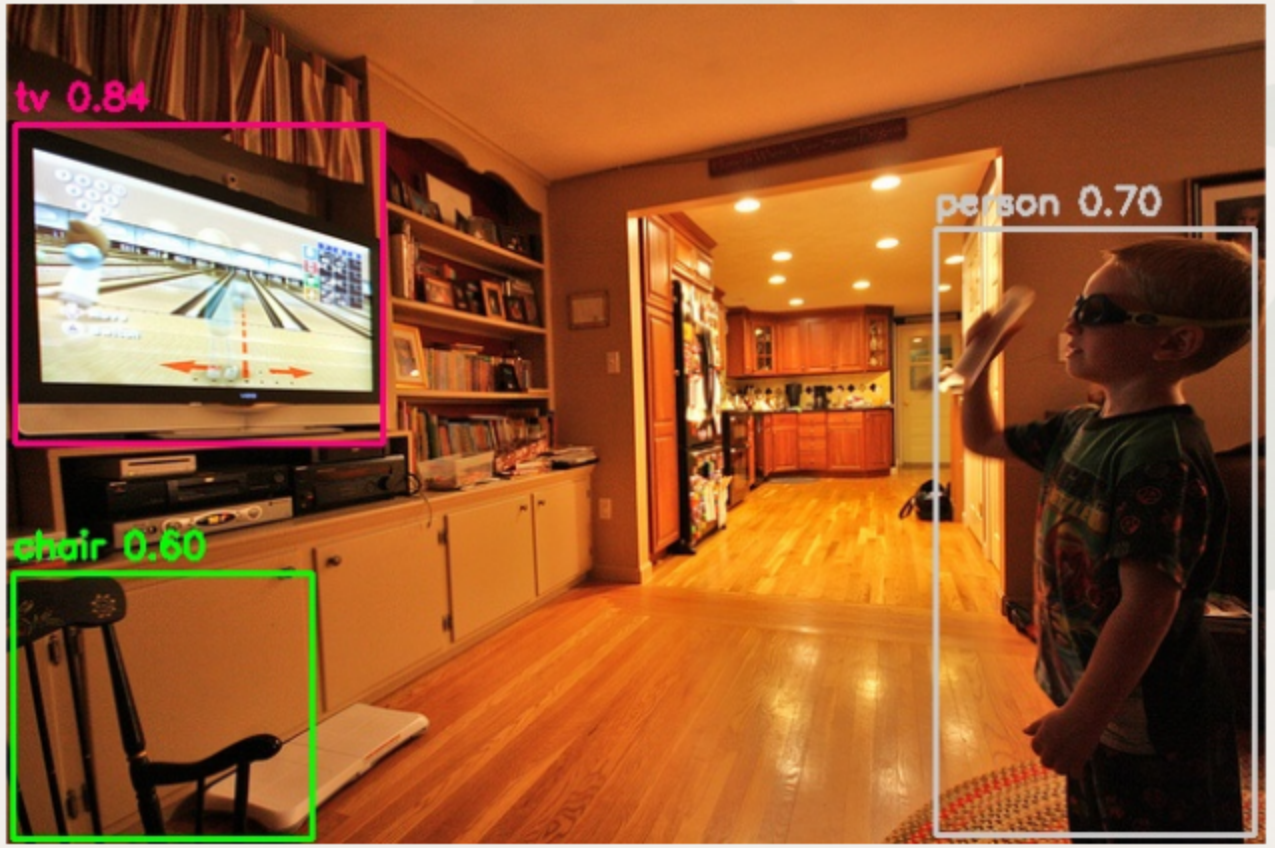
Propuesta de pasantía, §5. Plan de actividades; informe, §2.1

Detección de objetos en *IA*

¿Qué hay y dónde está?

La detección de objetos es una tarea de visión por computador que permite conocer qué elementos aparecen en una imagen y dónde se encuentran.

El modelo entrega una categoría, una caja y una confianza por detección.



Ejemplo: televisor, persona y silla en una misma imagen.

Qué significa detectar *correctamente*

Un detector identifica los objetos de una imagen y localiza cada uno mediante una caja delimitadora.

Clase

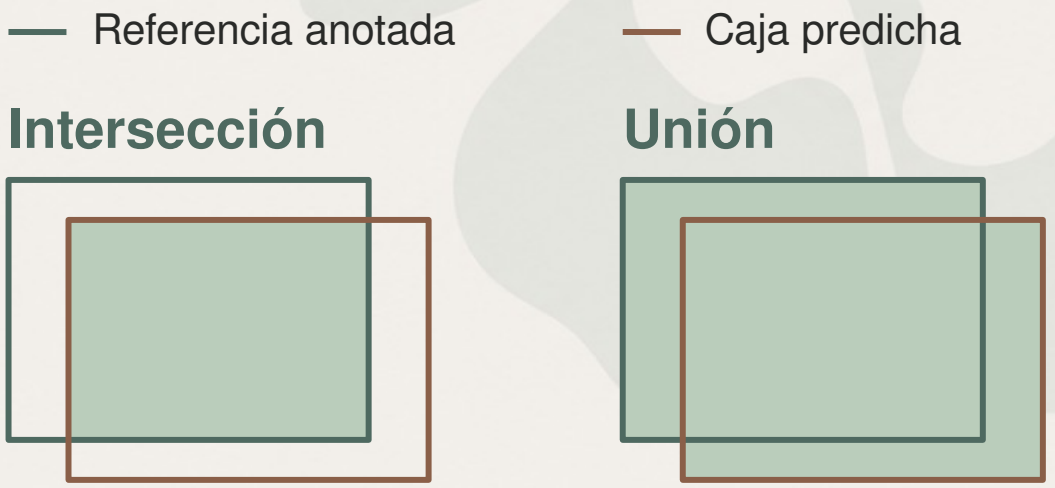
Categoría del objeto, como «silla».

Caja delimitadora (bounding box)

Rectángulo que aproxima la posición y el tamaño del objeto en la imagen.

Confianza

Puntuación asignada por el modelo.



IoU = área de intersección / área de unión

0: sin solapamiento. 1: coincidencia total.

Informe, §1.1; Build/Testing/benchmark/evaluate.py, función iou

Fase 1 · Objetivo específico 1 · Criterios de evaluación

Precisión, recall y mAP

Acierto = clase correcta e IoU ≥ 0,50, con emparejamiento uno a uno.

TP: acierto. FP: detección incorrecta. FN: objeto visible no recuperado.

PRECISIÓN	RECALL	F1
Proporción correcta de lo detectado.	Proporción recuperada de lo visible.	Equilibrio entre precisión y recall.

mAP50	Promedio entre clases con IoU ≥ 0,50.
mAP50–95	Exige un ajuste de cajas más preciso.

Informe, §1.1. COCO (Lin et al., 2014) y Manning et al. (2008)

Fase 1 · Objetivo específico 1 · Fundamentos de selección

Arquitecturas y eficiencia *móvil*

DOS ETAPAS

Faster R-CNN: propuesta de regiones y refinamiento.

UNA ETAPA

YOLO, SSD y EfficientDet: predicción directa de cajas y clases.

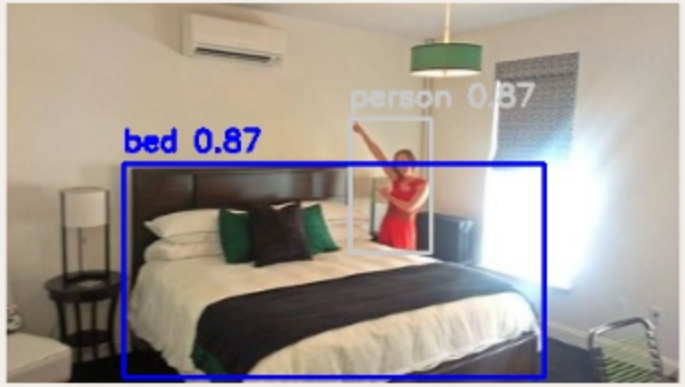
EJECUCIÓN MÓVIL

Modelos ligeros, TensorFlow Lite y precisión Float32 / Float16.

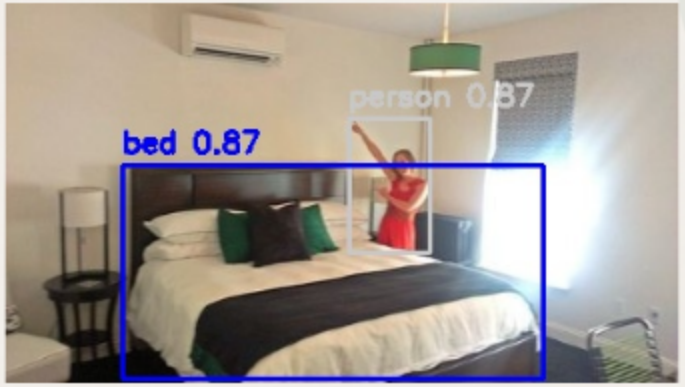
Informe, §§1.3–1.5. Ren et al. (2015), Liu et al. (2016), Tan et al. (2020)

Comparación de seis *candidatos*

YOLOv8s Float32



YOLOv8s Float16



YOLO11n Float32



YOLO11n Float16



SSD MobileNetV1



EfficientDet-Lite2

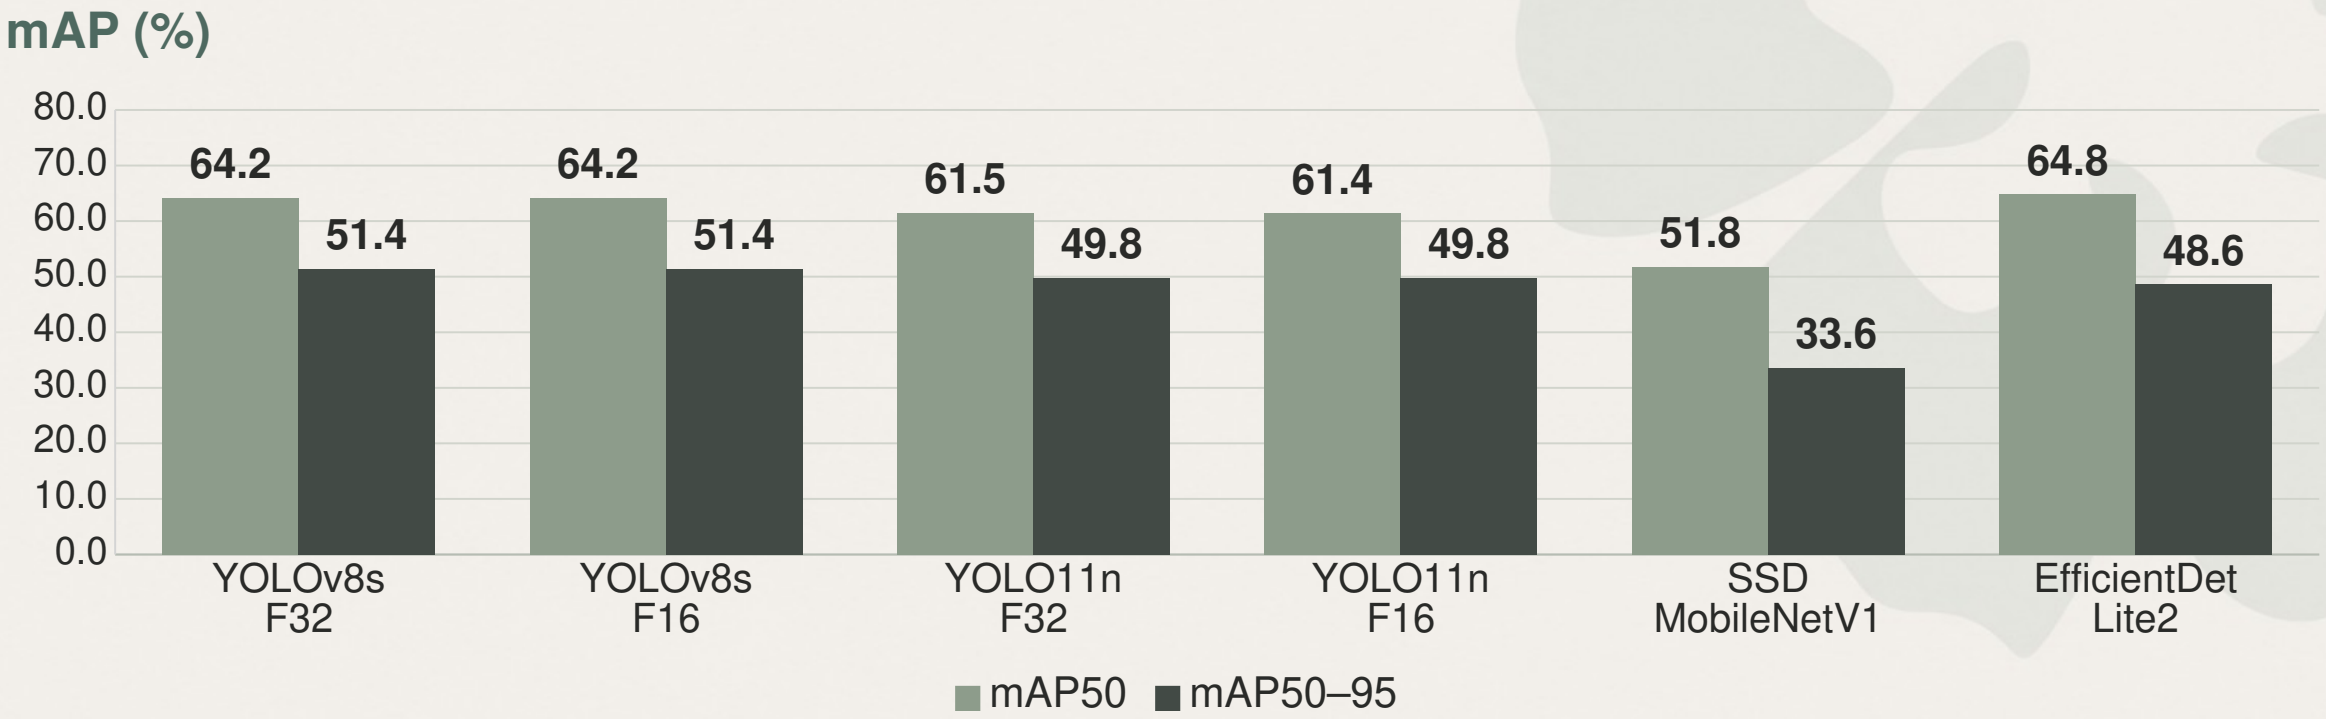


Misma escena. Cada salida conserva sus cajas, clases y puntuaciones.

Informe, §§2.2–2.5; Build/models_comparison/results/

Fase 1 · Objetivo específico 1 · Resultados en escritorio

Exactitud de los *candidatos*



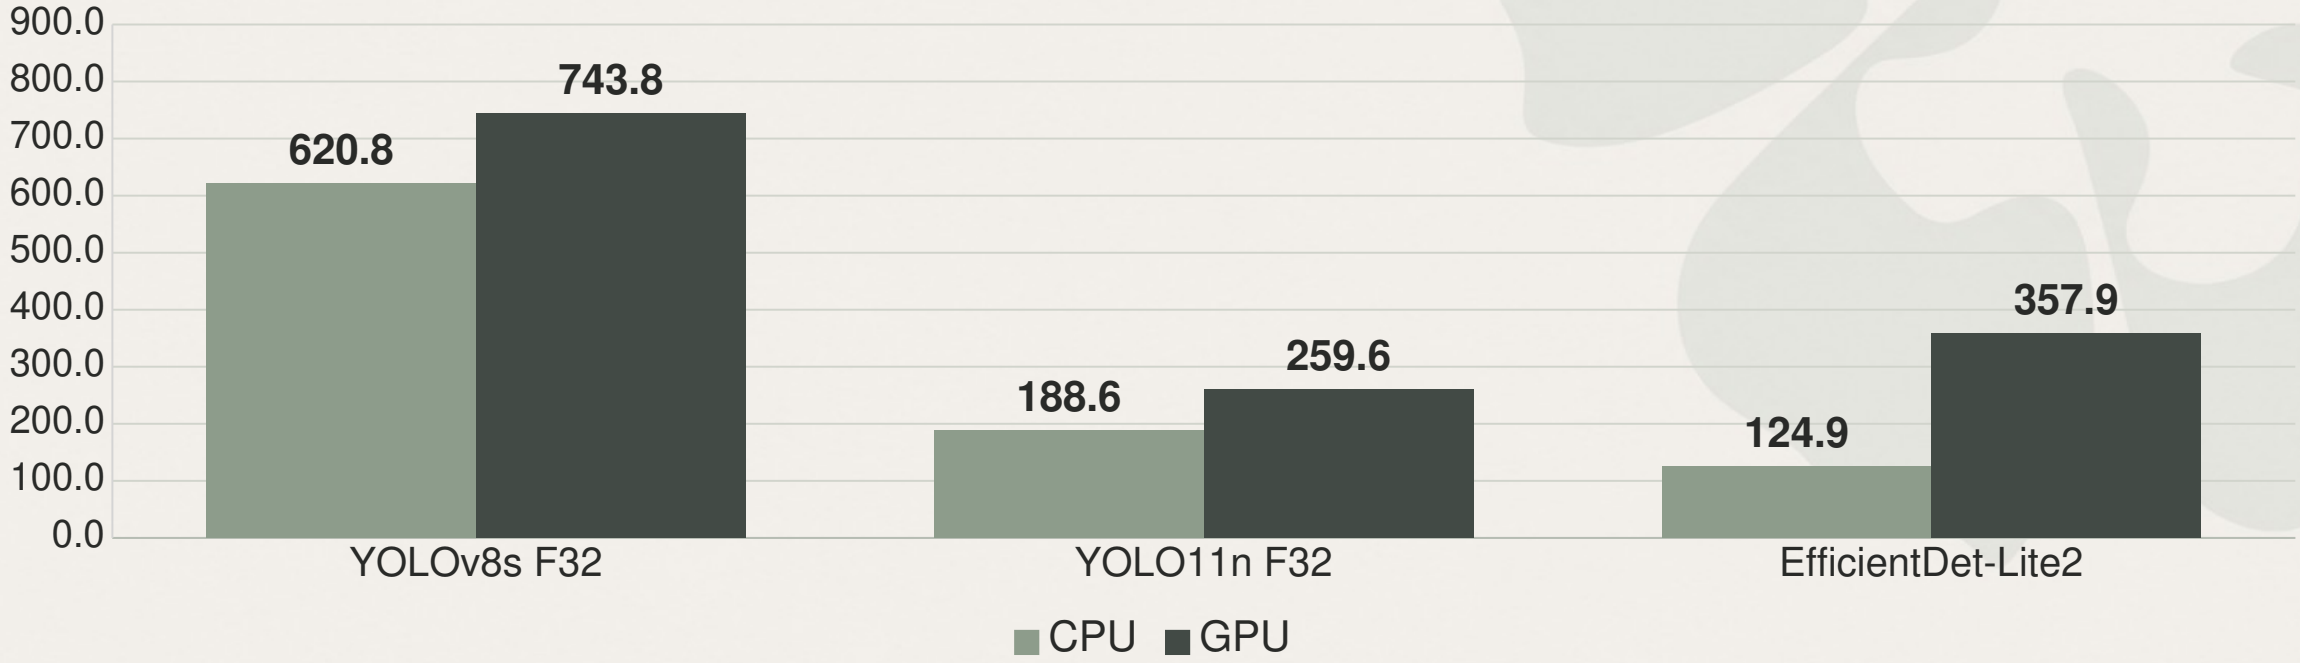
F1: 70,2 % en YOLOv8s y 69,5 % en EfficientDet-Lite2.

Informe, tablas 2.1–2.2; Build/models_comparison/results/desktop.md

Fase 1 · Objetivo específico 1 · Costo de ejecución

CPU y GPU en el teléfono *evaluado*

Inferencia aislada (ms)



SSD MobileNetV1: 23,4 ms en CPU. GPU sin soporte estable.

Informe, tablas 2.3–2.4; Build/models_comparison/results/android.md

Fase 1 · Objetivo específico 1 · Selección final

Por qué *EfficientDet-Lite2*

124,9 ms

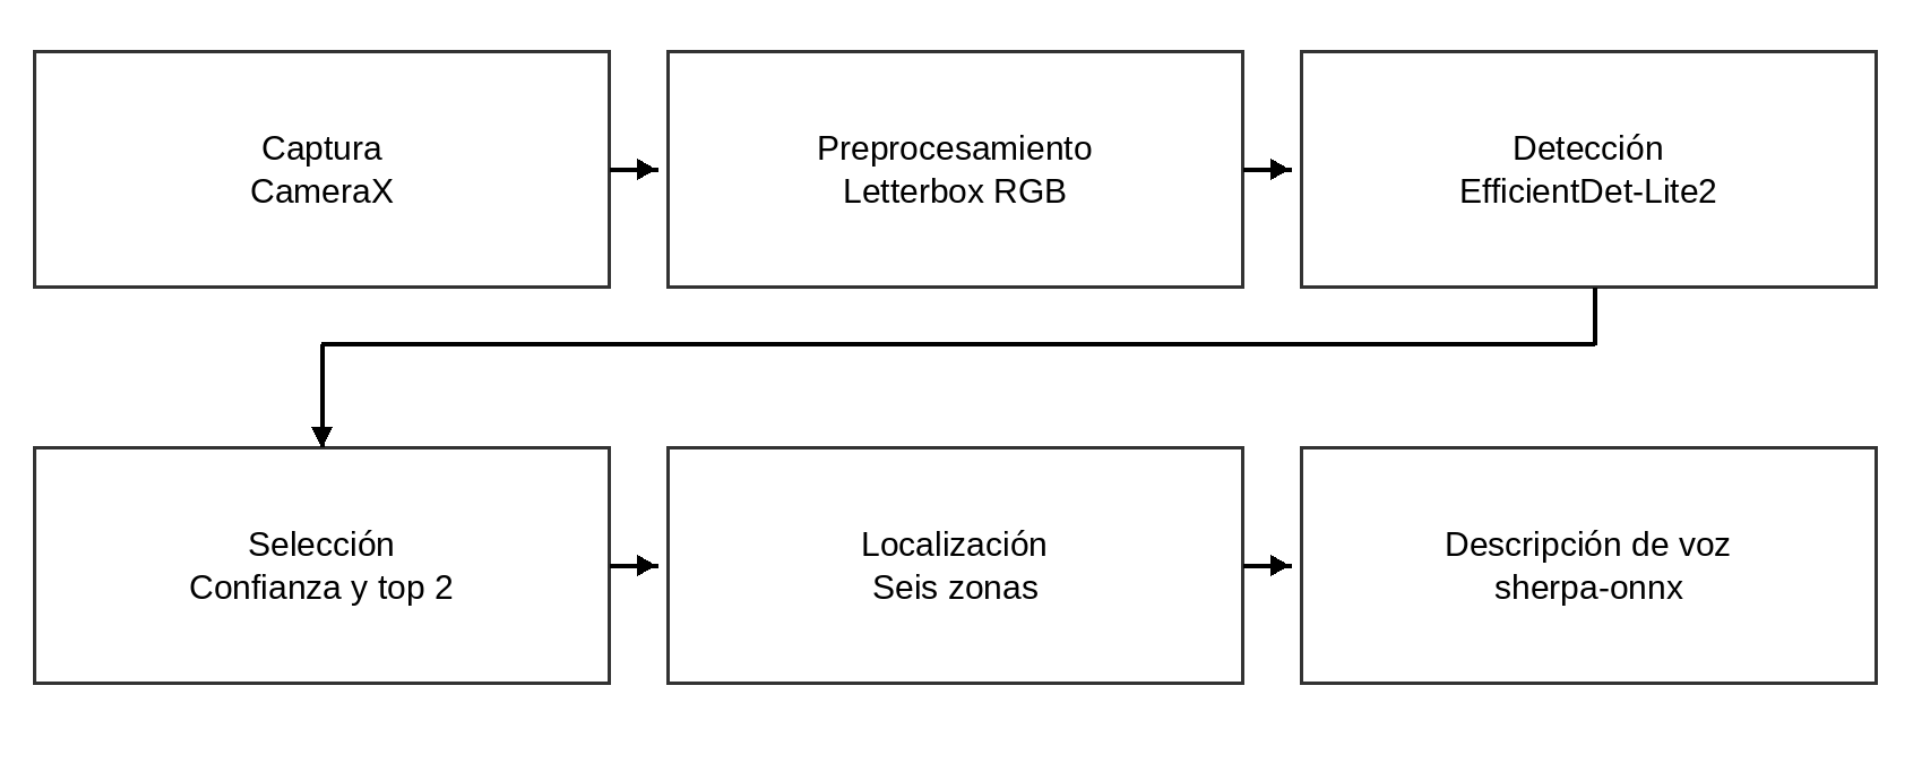
mAP50 0,648 recall 0,677 RAM 65,8 MB

Una menor latencia de inferencia reduce
la espera por la descripción auditiva del entorno.

Informe, §§2.7–2.8; comparación en Redmi Note 13

Fase 2 · Objetivo específico 2 · Diseño e implementación

Arquitectura del *prototipo*



CÁMARA + DETECTOR + LOCALIZACIÓN + VOZ LOCAL

Informe, §3.1 y figura 3.1

Fase 2 · Objetivo específico 2 · Organización del código y aprendizajes

Desarrollo Android y buenas *prácticas*

MVVM (Model–View–ViewModel) con módulos por responsabilidad.

ESTRUCTURA DEL PROYECTO

ui/	Pantallas y controles.
viewmodel/	Estado y flujo de captura.
modules/	Procesamiento y voz.
model/	Datos y lógica comprobable.
data/	Preferencias con DataStore.

Kotlin · AndroidX · ViewBinding · Navigation

DataStore · LiteRT · sherpa-onnx · Gradle

PRÁCTICAS APLICADAS

Concurrencia controlada

Coroutines fuera del hilo de interfaz.
Mutex para evitar tareas simultáneas.

Gestión del ciclo de vida

Liberación de vistas, cámara, detector y audio al cerrar sus componentes.

Verificación y mantenimiento

Pruebas unitarias e instrumentadas.
Versiones de dependencias fijadas.

Aprendizaje: integrar modelos de IA en una app Android modular y comprobable.

AssistiveVision: código Kotlin, app/build.gradle.kts y gradle/libs.versions.toml

Fase 2 · Objetivo específico 2 · Módulos de entrada

Captura y *preprocesamiento*

BAJO DEMANDA

CameraX conserva el fotograma reciente. Capturar inicia un único ciclo.

448 × 448

Letterbox conserva la proporción.

Tensor UINT8 de 3 canales.
Relleno gris: 114.

Fase 2 · Objetivo específico 2 · Módulos de detección y filtrado

Detección y selección de *objetos*

10 clases

Persona · silla · sofá · cama · mesa
Inodoro · televisor · portátil
Lavabo · refrigerador

0,30

Confianza por defecto

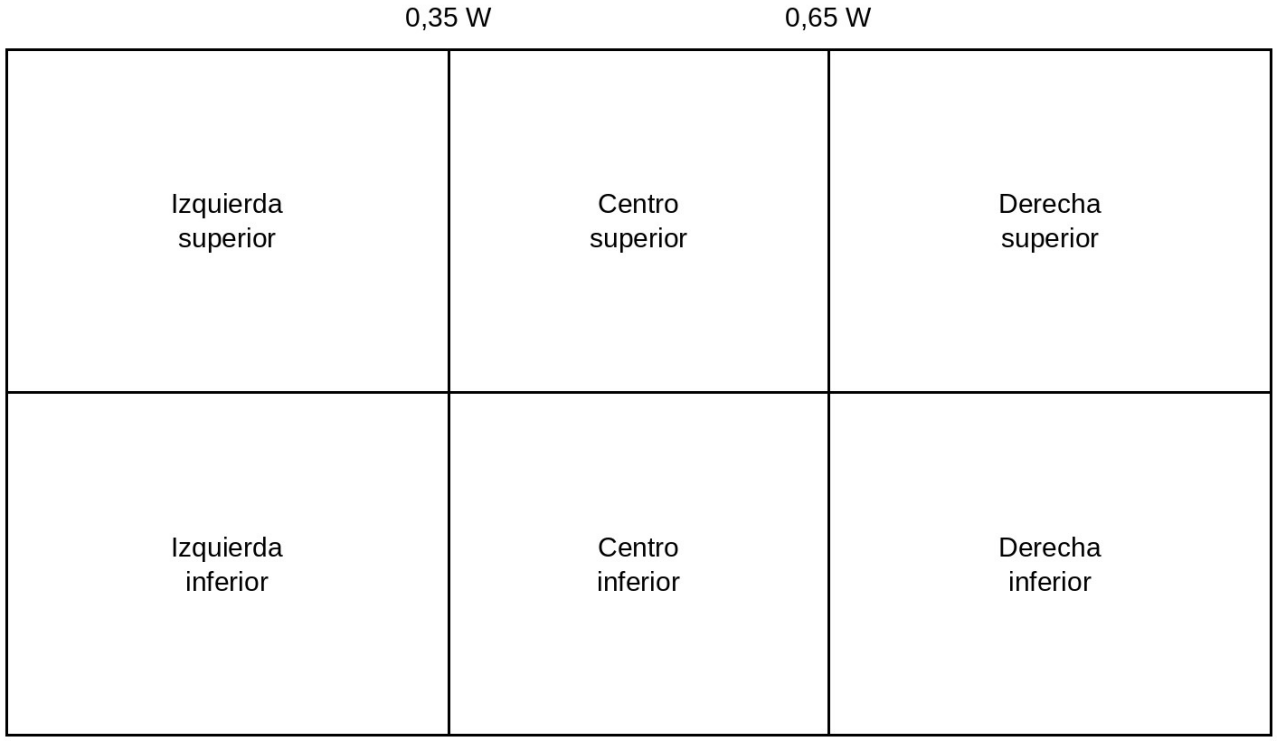
2

Objetos anunciados por defecto

Informe, §§3.5 y 3.7; clases COCO de la tabla 3.1

Fase 2 · Objetivo específico 2 · Localización espacial

Ubicación relativa en seis *zonas*



“Una silla abajo a la izquierda…”

La referencia es el encuadre de la cámara.

Informe, §3.6 y figura 3.3

Fase 2 · Objetivo específico 2 · Audio y operación manual

Voz local y ciclo de *interacción*

D = artículo + nombre del objeto + frase de ubicación

D_1, D_2 y D_3 siguen el orden de confianza de los objetos seleccionados.

1 objeto	Hay D_1.
2 objetos	Hay D_1 y D_2.
3 objetos	Hay D_1, también hay D_2 y D_3.

EJEMPLO CON DOS OBJETOS

“Hay una silla abajo a la izquierda de donde estás apuntando y un televisor arriba a la derecha de donde estás apuntando.”

Síntesis local en español o inglés. Al terminar la voz, se libera la captura.

Fase 2 · Objetivo específico 2 · Interacción con la aplicación

Interfaz, ajustes y *accesibilidad*





CONFIGURACIÓN

Idioma, velocidad, confianza, número de objetos y vista previa.

INTERACCIÓN

Controles identificables, avisos de estado y disparador físico compatible.

Informe, §§3.10–3.11. Capturas reales de la app en emulador

Diseño y espacios de *captura*



Dormitorio



Cocina



Baño

33 × 6

198 fotos
889 instancias
10 clases

30 recintos en 6 inmuebles

Fase 3 · Objetivo específico 3 · Posicionamiento y lentes

Soportes y campo *visual*



Cabeza



Pecho



Palo de selfie

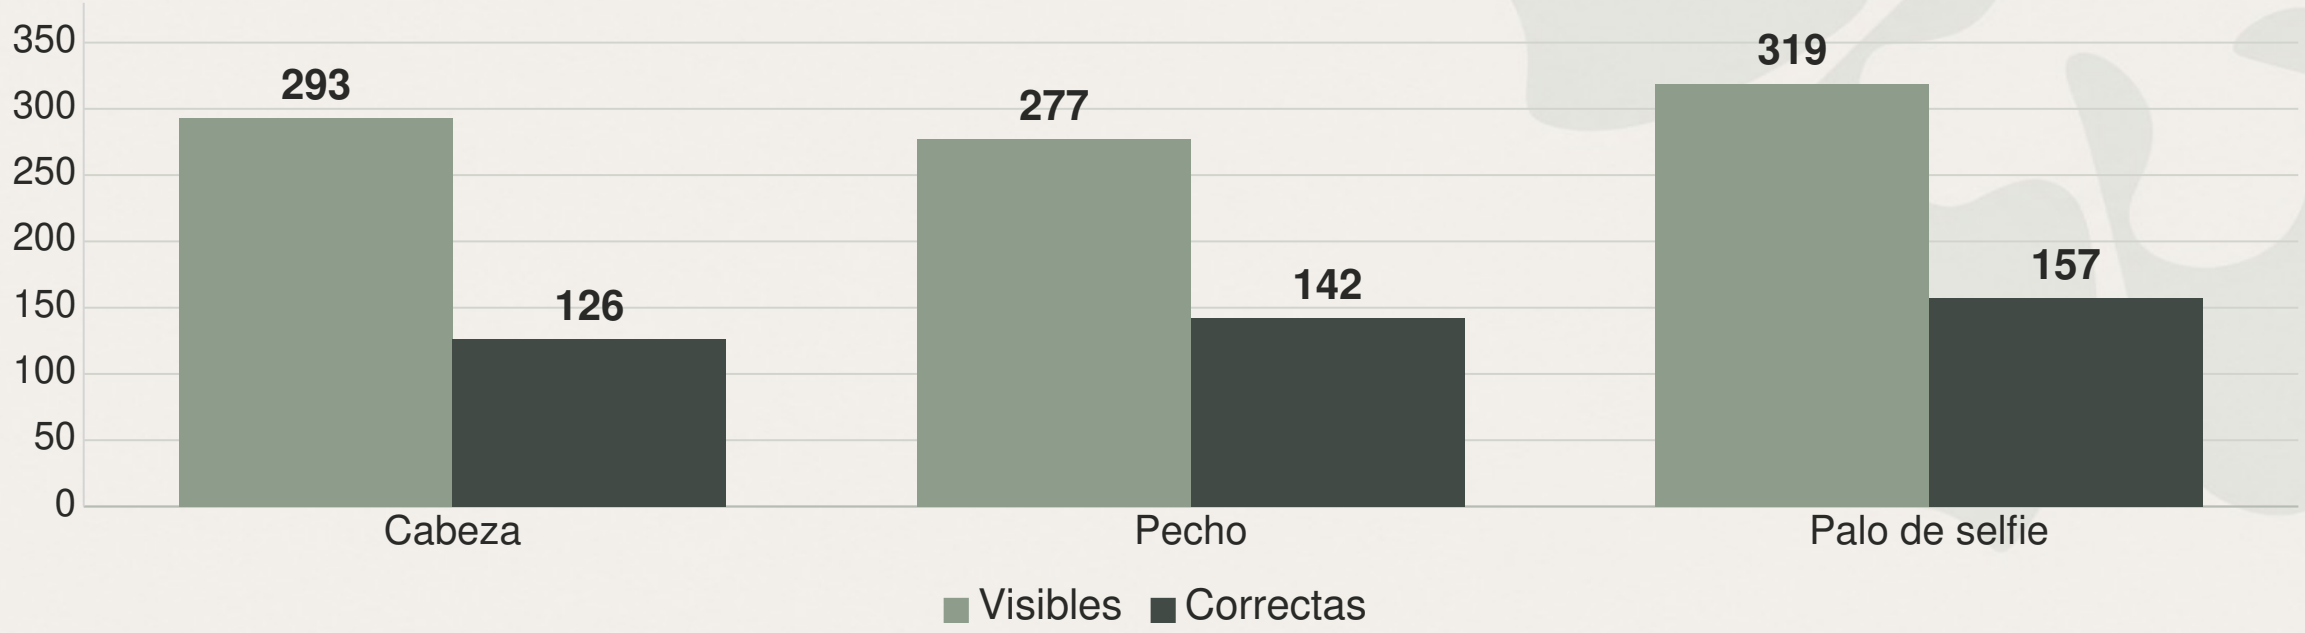
Cada soporte combina 1x y 0,5x nominales. 33 fotografías por configuración.

Informe, §§3.2, 4.1.2. Fotografías del autor

Fase 3 · Objetivo específico 3 · Resultados agrupados

Comparación de *montajes*

Instancias visibles y detecciones correctas



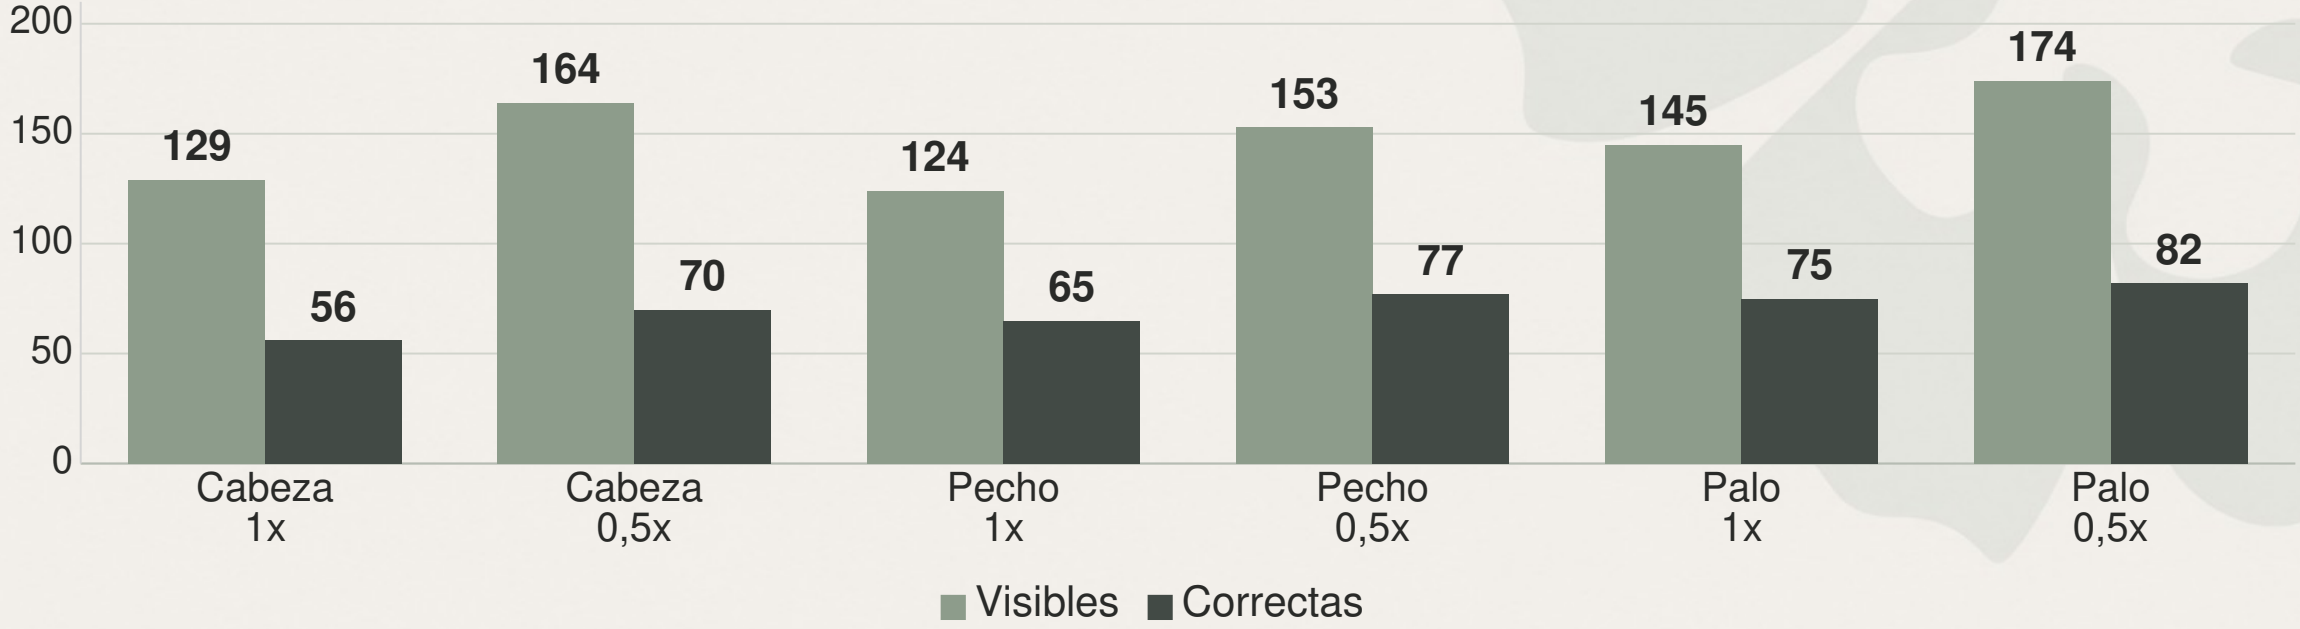
F1: 53,1 % cabeza · 60,2 % pecho · 58,6 % palo de selfie

Informe, §4.2; summary.csv, agregación por montaje

Fase 3 · Objetivo específico 3 · Montaje y lente

Las seis configuraciones de *captura*

Instancias por configuración



82 aciertos: palo 0,5x. Mayor F1: pecho 1x, 61,9 %.

Informe, §4.3; summary.csv, agregación por configuración

Fase 3 · Objetivo específico 3 · Inferencia estadística exploratoria

Comparaciones dentro del *grupo*

+17

detecciones correctas frente a pecho 1x

Palo de selfie 0,5x

Alternativa	Δ por grupo	IC 95 %
Pecho 1x	+0,515	[0,121; 0,939]
Pecho 0,5x	+0,152	[–0,182; 0,515]
Palo 1x	+0,212	[–0,242; 0,667]

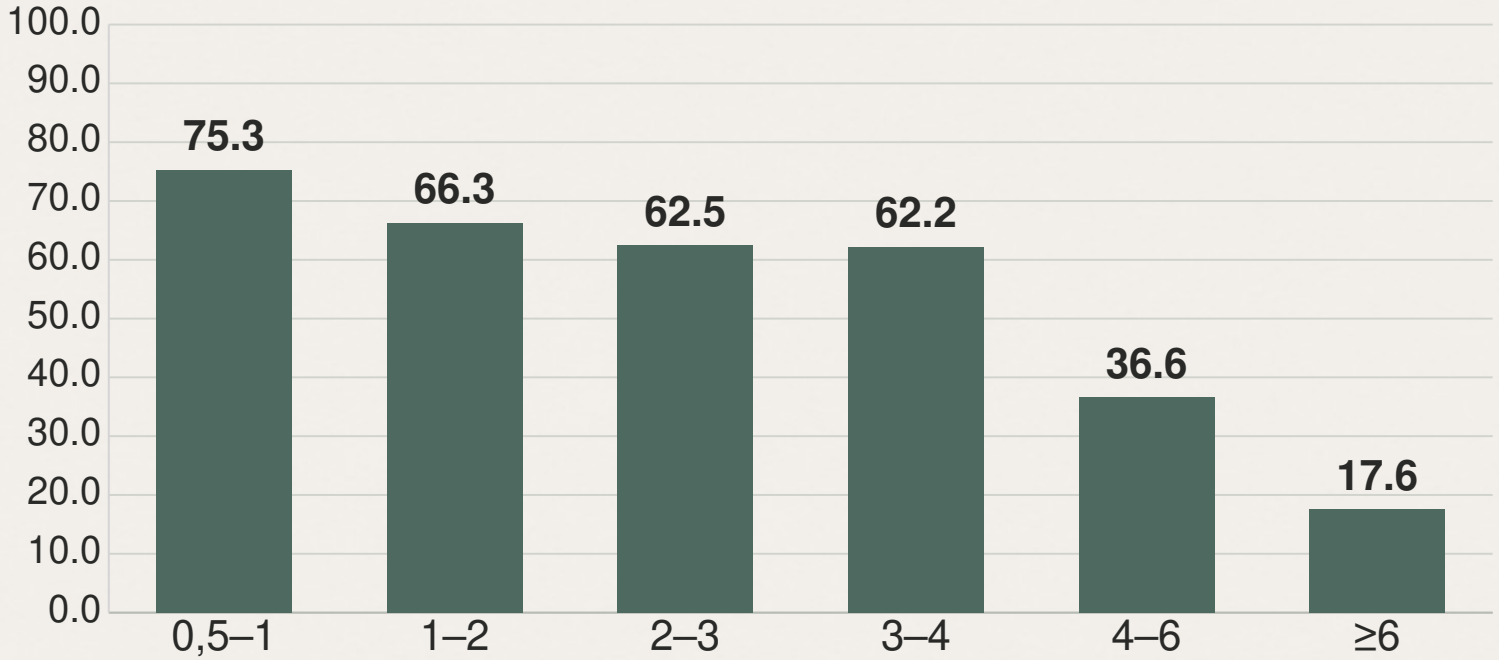
Los dos últimos intervalos incluyen cero.

Informe, §4.3; scenes/paired_count_differences.csv

Fase 3 · Objetivo específico 3 · Análisis geométrico

Detección por distancia *estimada*

Recall (%) por banda de distancia estimada (m)

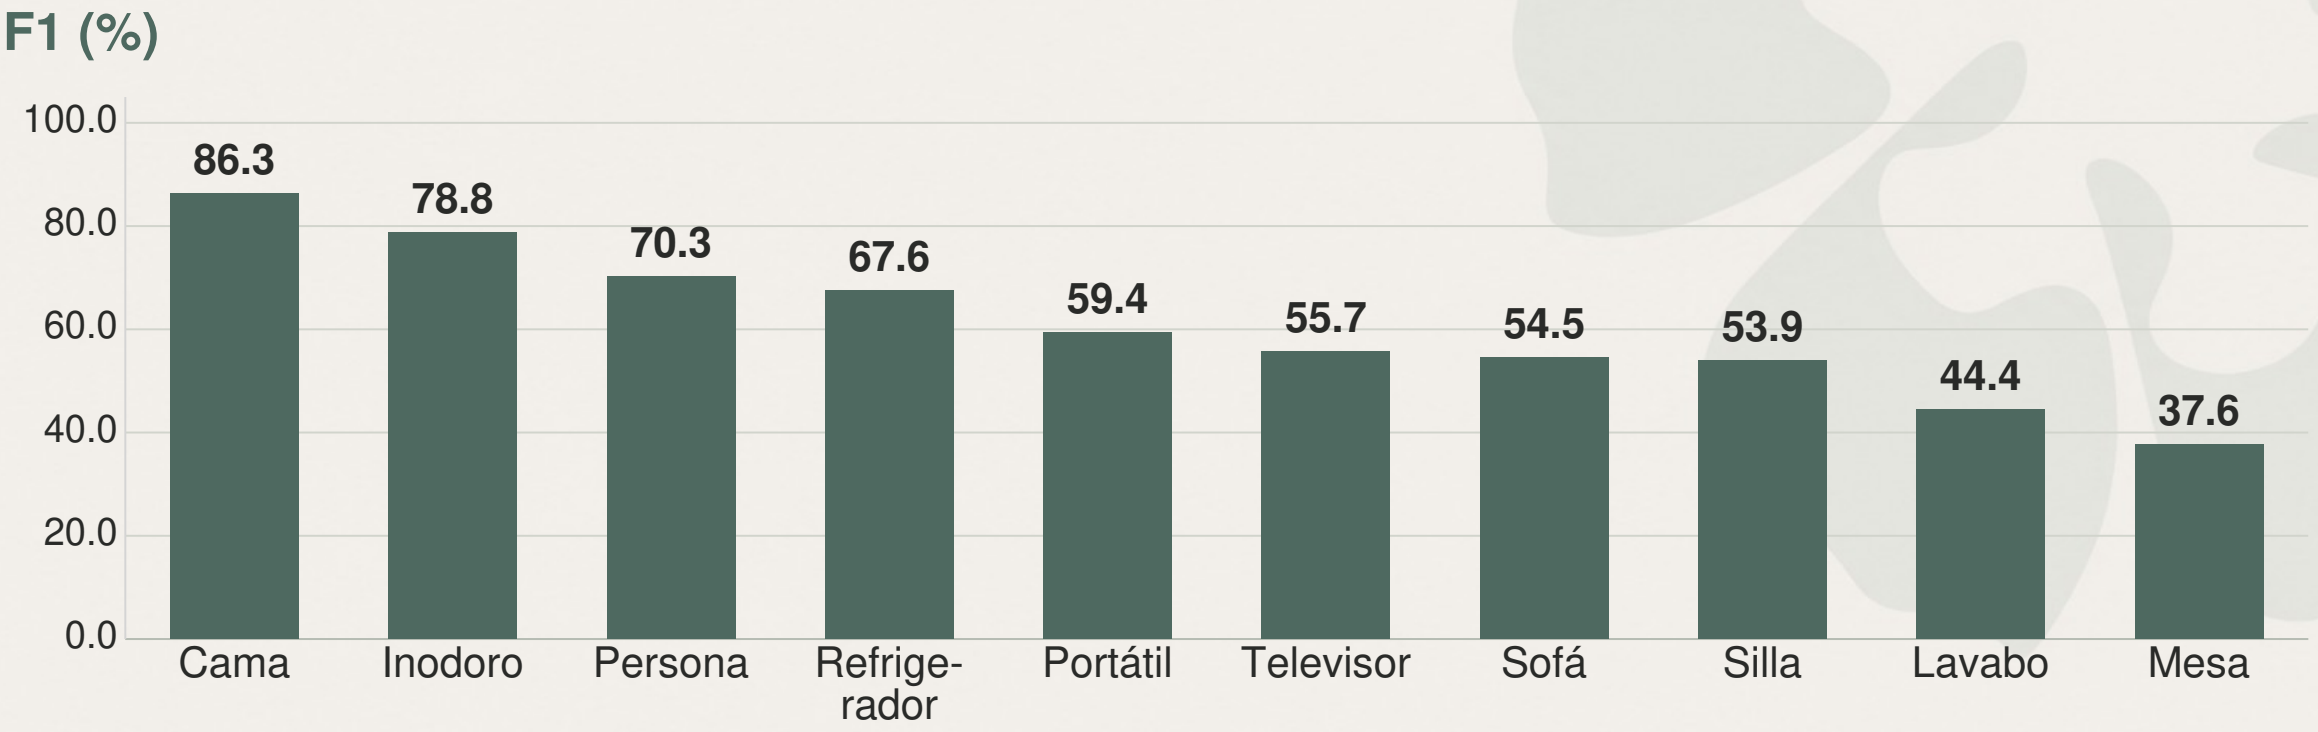


Banda (m)	IC 95 % del recall
0,5–1	57,0–94,1 %
1–2	54,7–78,4 %
2–3	50,0–73,4 %
3–4	45,9–76,2 %
4–6	25,0–48,1 %
≥6	7,9–21,4 %

Informe, §4.4; depth/depth_bands.csv

Fase 3 · Objetivo específico 3 · Exactitud y composición del conjunto

Desempeño por *clase*

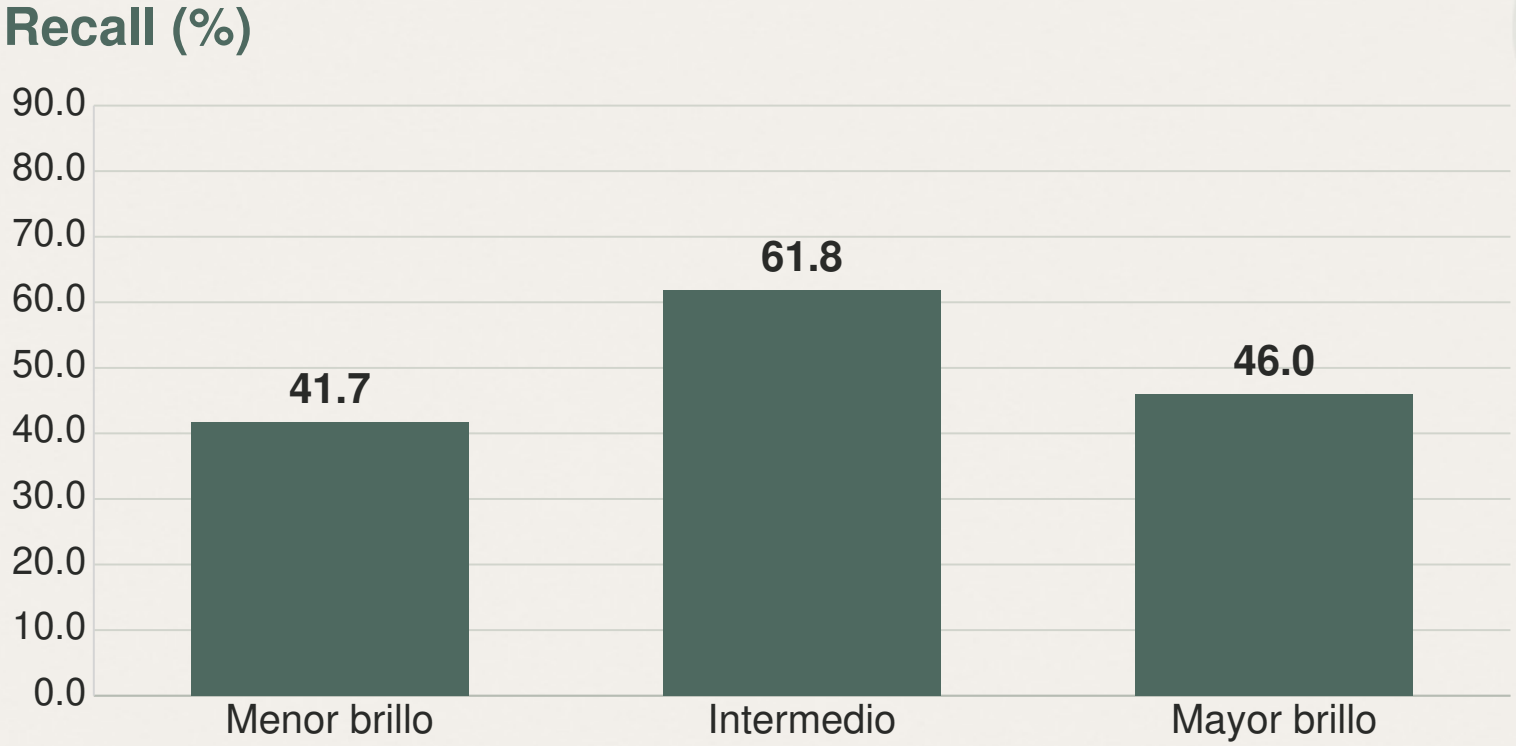


438 de 889 anotaciones son sillas: 49,3 % del conjunto.

Informe, §4.5; per_class.csv, conteos agregados de las seis configuraciones

Fase 3 · Objetivo específico 3 · Condiciones de captura

Brillo digital de las *escenas*



66

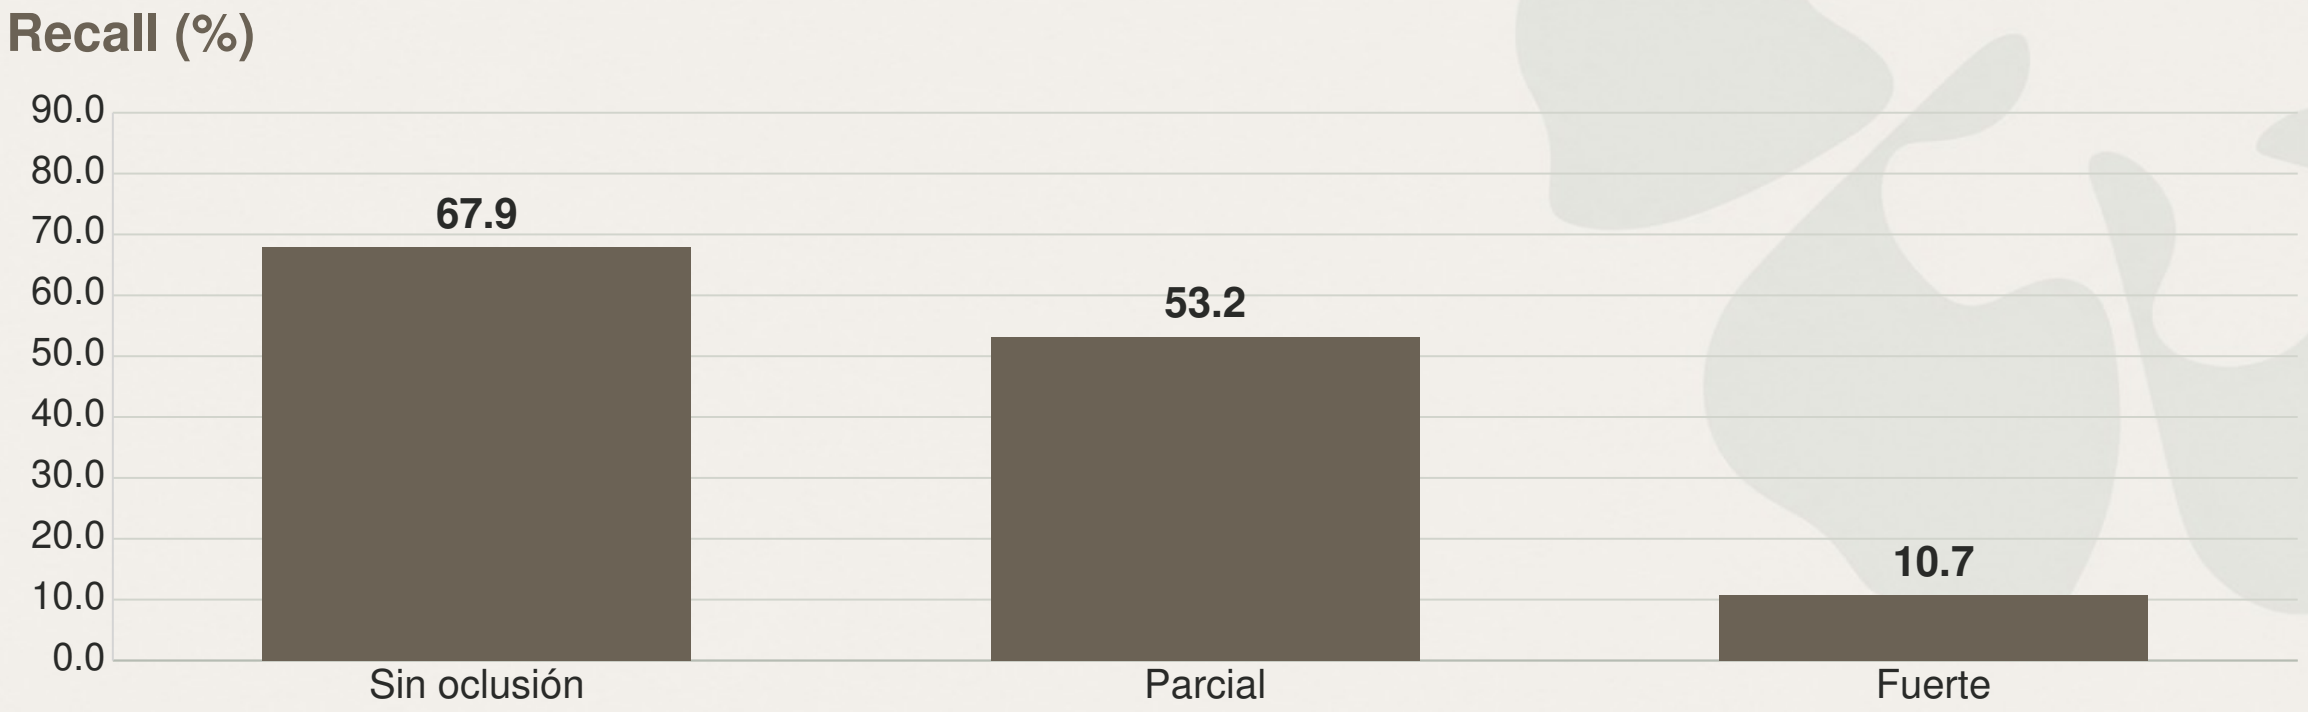
fotografías por grupo

Brillo de la imagen, sin medición en lux.

Informe, §4.8; results/brightness/summary.json

Fase 3 · Objetivo específico 3 · Visibilidad parcial de los objetos

Oclusión *observada*



39 instancias inciertas se analizan por separado.

Informe, §4.8.1; occlusion/results/severity.csv y uncertainty.csv

Fase 3 · Objetivo específico 3 · Medición en emulador Android

Distribución del *procesamiento*

352,4 ms

Mediana del procesamiento por imagen

P95: 419,9 ms

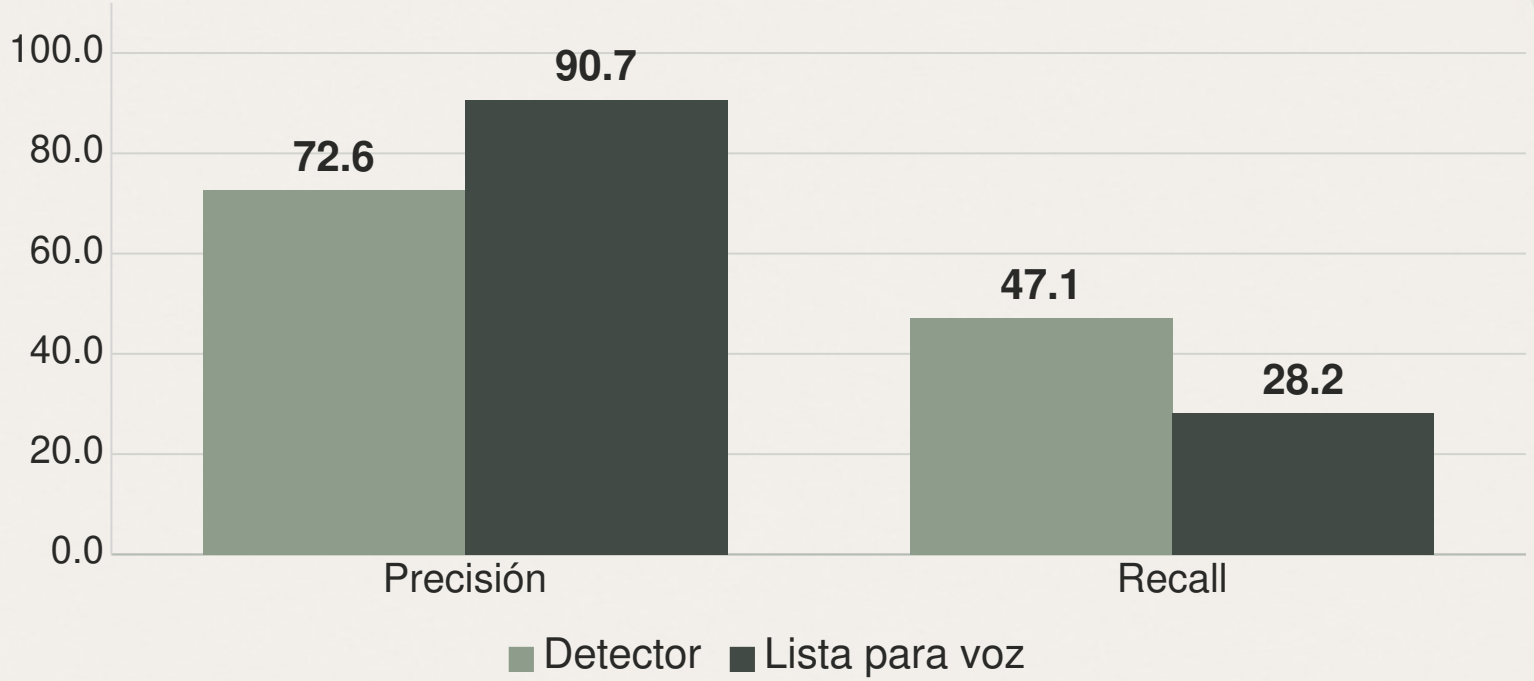
Decodificación, preprocesamiento y detección. Audio fuera de esta medición.

Informe, §4.7; results/brightness/summary.json

Fase 3 · Objetivo específico 3 · Selección, formato y síntesis

Evaluación de la salida *auditiva*

Palo de selfie 0,5x · porcentajes



49 / 54

selecciones correctas para el anuncio

Formato bilingüe y síntesis local verificados.

Informe, §§4.5 y 4.9; summary.csv, palo de selfie 0,5x

Conclusiones · Síntesis por objetivo

Hallazgos frente a los *objetivos*

Objetivo 1 · Seleccionar el modelo

EfficientDet-Lite2: mAP50 de 0,648 e inferencia aislada de 124,9 ms en Redmi.

Objetivo 2 · Desarrollar el prototipo

Android integra cámara, detección, seis zonas y descriptores de voz locales.

Objetivo 3 · Evaluar el desempeño

198 fotos: detección, procesamiento y salida auditiva.

Anexo A · Repositorios del proyecto

Código, informe y *reproducción*

INDOOR-DETECT

Datos, anotaciones, resultados e informe final.

github.com/diomedescerda/indoor-detect

AssistiveVision · main

Aplicación Android, APK e instrucciones de compilación.

github.com/diomedescerda/AssistiveVision

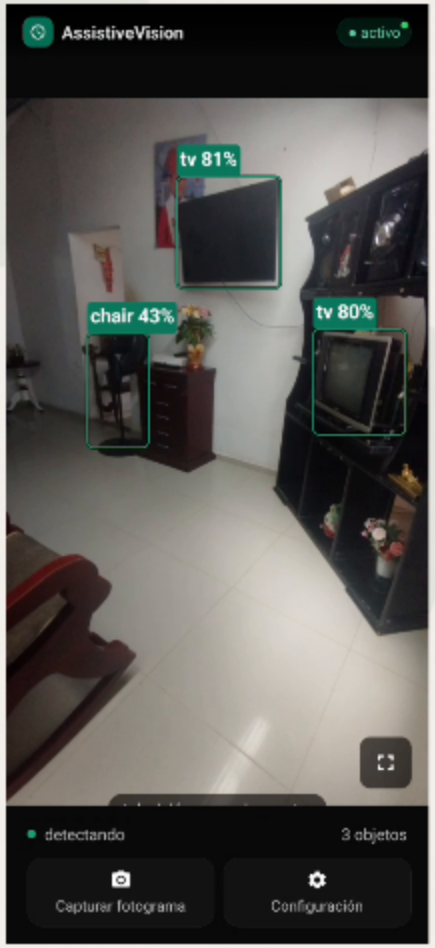
Demostración final

AssistiveVision en *funcionamiento*

Captura y descripción auditiva del entorno

3 min 26 s · audio original

Abrir el archivo de video



Demostración de la aplicación · video del autor

Gracias

Preguntas y conversación

AssistiveVision / 2026