AssistiveVision

Sistema de identificación y localización espacial de objetos basado en visión por computador para asistencia a personas con discapacidad visual

Diomedes Farid Cerda Leon

Directora: Idanis Beatriz Diaz Bolaño
Codirector: Aquiles Alfonso Cohen Llanes

Percepción del entorno interior



¿Qué hay delante?

Reconocer objetos y comunicar su posición mediante una descripción auditiva.

Interior · teléfono Android · voz local

Propósito y objetivos

01 SELECCIONAR

Comparar exactitud y costo de ejecución del detector en Android.

02 INTEGRAR

Conectar cámara, detección, ubicación relativa y voz en una aplicación.

03 EVALUAR

Analizar detección, procesamiento y retroalimentación auditiva.

Antecedentes de asistencia visual

Meenakshi · 2022	Soporte corporal, dirección y distancia aproximada.
Guravaiah · 2023	Reconocimiento de objetos y etiquetas convertidas en voz.
Pawar · 2025[1]	SSD MobileNet con ejecución local.
Figura · 2025	Comparación de detectores y costo computacional.
More · 2025	YOLOv8 y TensorFlow Lite en Android.

[1] Preprint

Qué significa detectar correctamente

CLASE CORRECTA + IoU ≥ 0,50

PRECISIÓN

Proporción correcta de lo detectado.

RECALL

Proporción recuperada de lo visible.

F1

Equilibrio entre precisión y recall.

mAP50	Promedio entre clases con IoU ≥ 0,50.
mAP50–95	Exige un ajuste de cajas más preciso.

Informe, §1.1. COCO (Lin et al., 2014) y Manning et al. (2008)

Arquitecturas y eficiencia móvil

DOS ETAPAS

Faster R-CNN: propuesta de regiones y refinamiento.

UNA ETAPA

YOLO, SSD y EfficientDet: predicción directa de cajas y clases.

EJECUCIÓN MÓVIL

Modelos ligeros, TensorFlow Lite y precisión Float32 / Float16.

Informe, §§1.3–1.5. Ren et al. (2015), Liu et al. (2016), Tan et al. (2020)

Metodología del proyecto

01 REVISIÓN Y SELECCIÓN

80 imágenes y 257 anotaciones para comparar seis configuraciones.

02 DESARROLLO ANDROID

Integración modular de captura, detección, localización y voz.

03 EVALUACIÓN TÉCNICA

198 fotografías, 889 anotaciones y 33 grupos de captura.

Comparación de seis candidatos

MODELOS

YOLOv8s Float32 / Float16
YOLO11n Float32 / Float16
SSD MobileNetV1
EfficientDet-Lite2

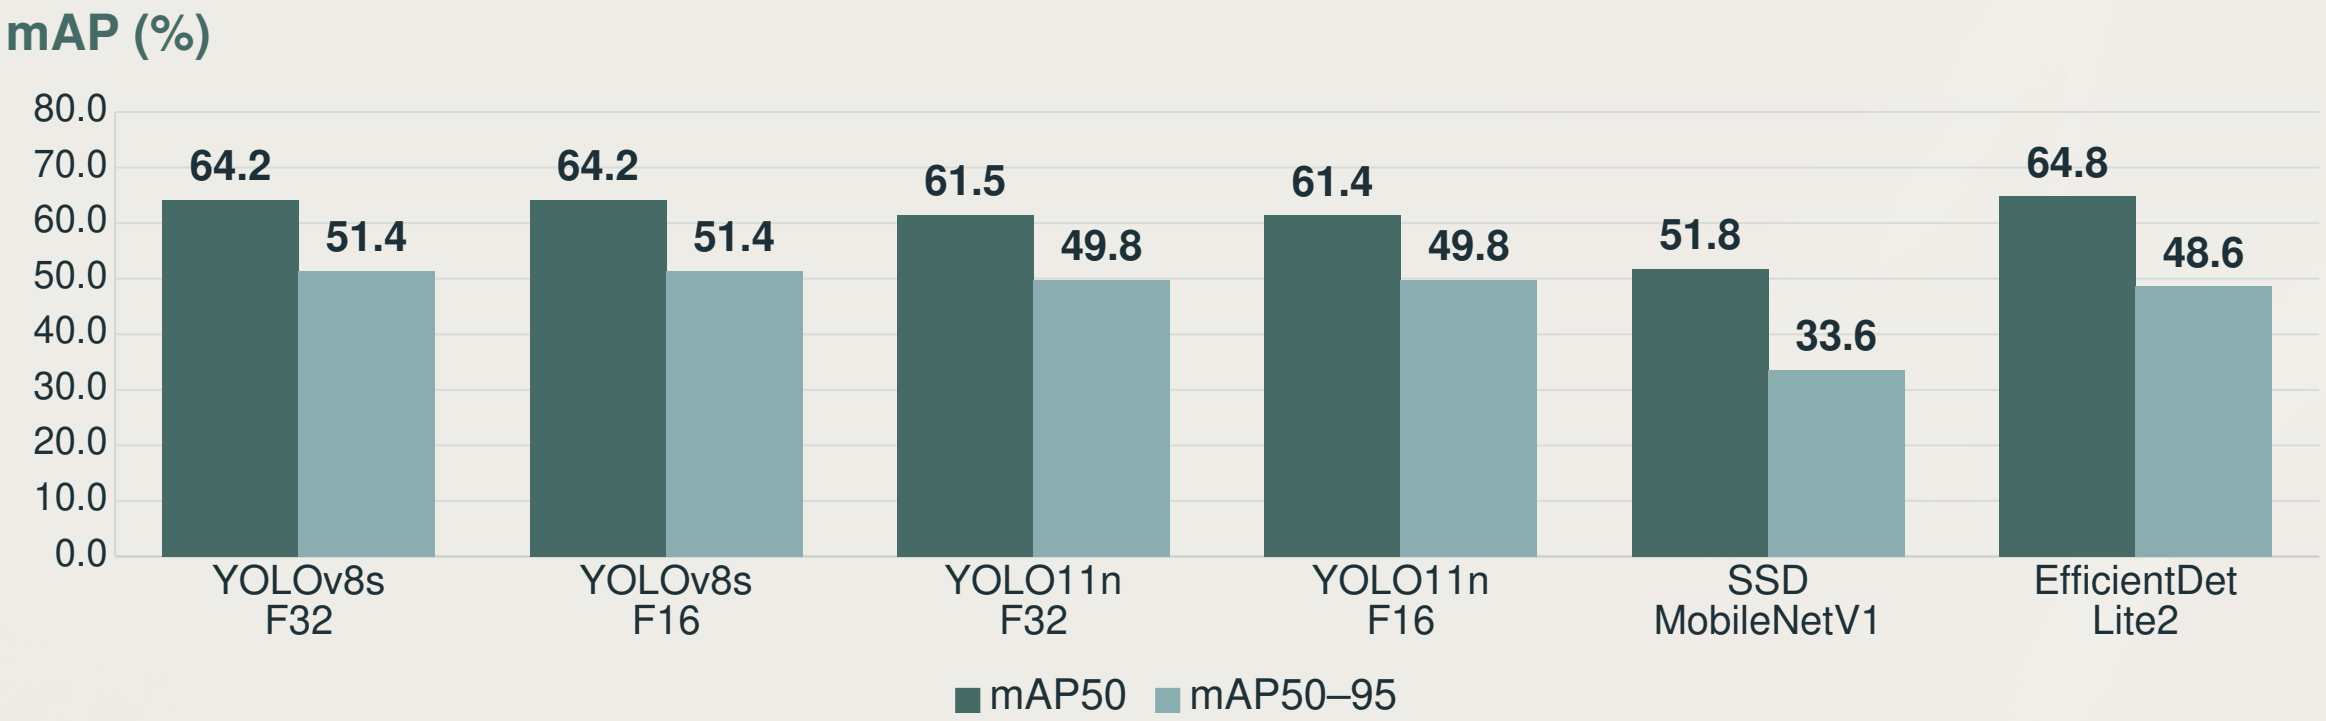
ENTORNO

80 imágenes · 257 anotaciones

Redmi Note 13 4G
Snapdragon 685 · Android 15
4 hilos · 50 ejecuciones/modelo

Informe, §§2.2–2.5; Build/models_comparison/results/

Exactitud de los candidatos

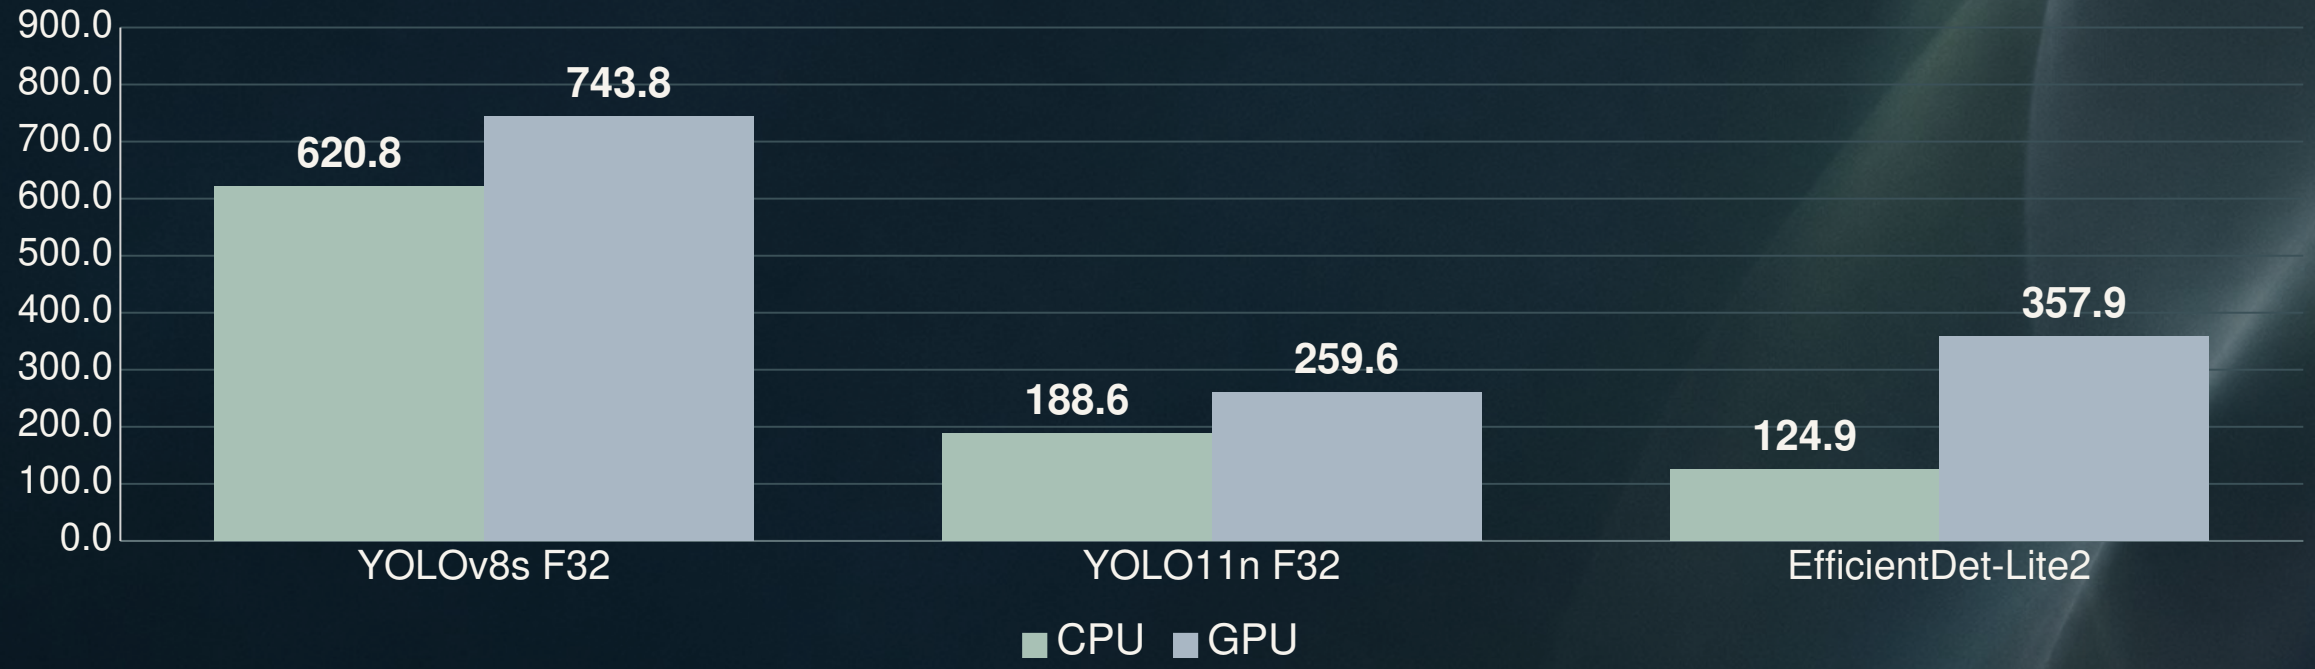


F1: 70,2 % en YOLOv8s y 69,5 % en EfficientDet-Lite2.

Informe, tablas 2.1–2.2; Build/models_comparison/results/desktop.md

CPU y GPU en el teléfono evaluado

Inferencia aislada (ms)



SSD MobileNetV1: 23,4 ms en CPU. GPU sin soporte estable.

Informe, tablas 2.3–2.4; Build/models_comparison/results/android.md

Float16: tamaño y tiempo

10 MB	5,2 MB
YOLO11n Float32	YOLO11n Float16
188,6 ms	198,1 ms

Menor archivo, sin aceleración observada en CPU.

Informe, §§1.5, 2.7.2 y 2.8

Por qué EfficientDet-Lite2

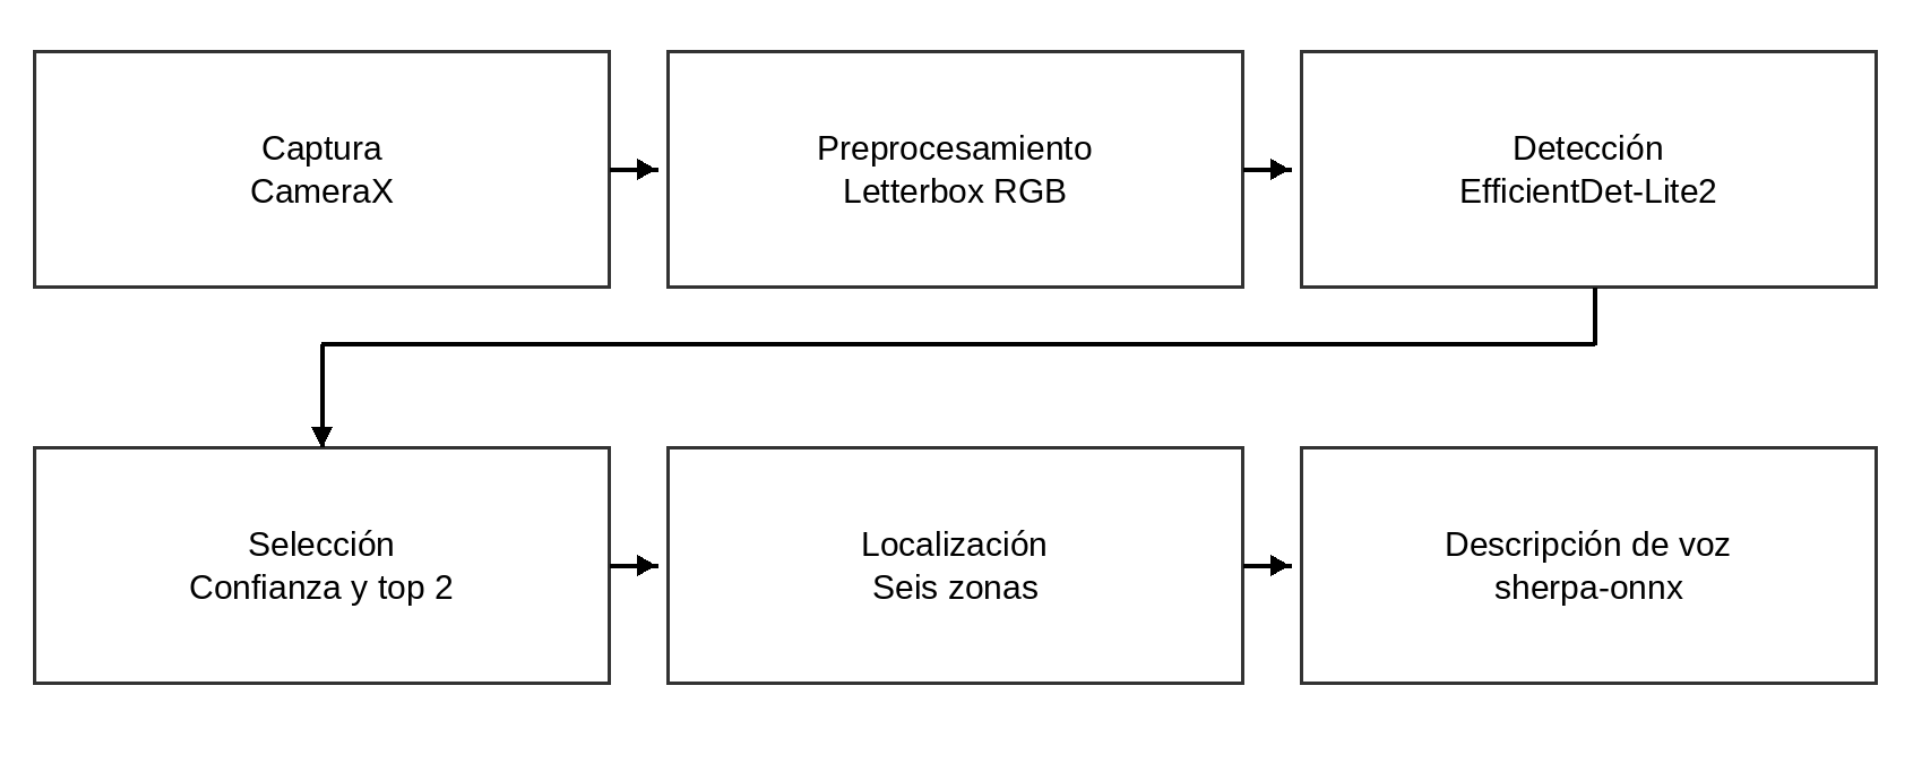
124,9 ms

mAP50 0,648 recall 0,677 RAM 65,8 MB

La detección debe terminar antes de emitir el mensaje de voz.

Informe, §§2.7–2.8; comparación en Redmi Note 13

Arquitectura del prototipo



CÁMARA + DETECTOR + LOCALIZACIÓN + VOZ LOCAL

Informe, §3.1 y figura 3.1

Captura y preprocesamiento

BAJO DEMANDA

CameraX conserva el fotograma reciente. Capturar inicia un único ciclo.

448 × 448

Letterbox conserva la proporción.

Tensor UINT8 de 3 canales.
Relleno gris: 114.

Detección y selección de objetos

10 clases

Persona · silla · sofá · cama · mesa
Inodoro · televisor · portátil
Lavabo · refrigerador

0,30

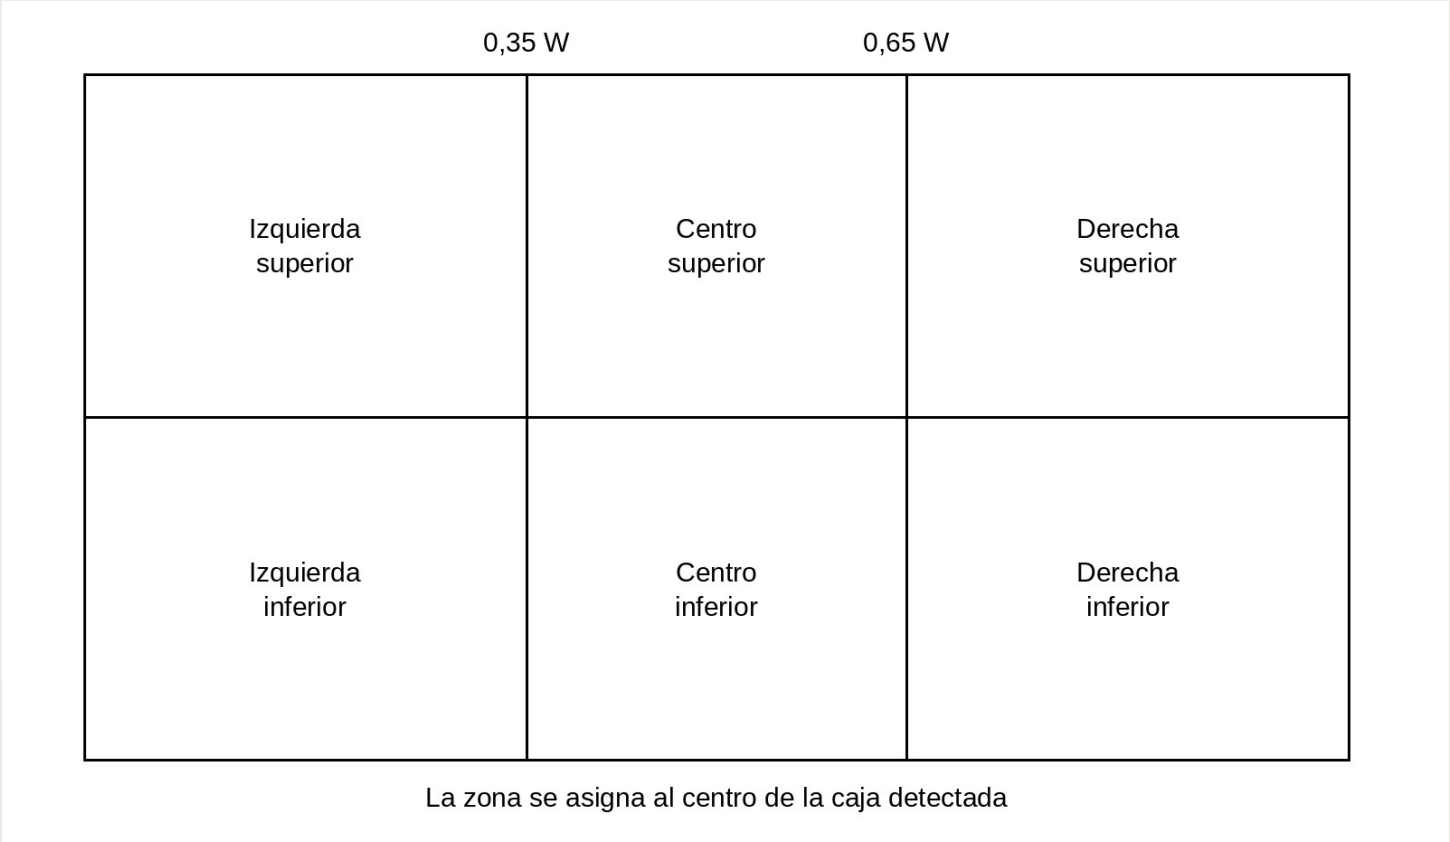
Confianza por defecto

2

Objetos anunciados por defecto

Informe, §§3.5 y 3.7; clases COCO de la tabla 3.1

Ubicación relativa en seis zonas



“Una silla abajo a la izquierda…”

La referencia es el encuadre de la cámara.

Informe, §3.6 y figura 3.3

Voz local y ciclo de interacción

“Hay una silla abajo a la izquierda de donde estás apuntando y un televisor arriba a la derecha de donde estás apuntando”

ESPAÑOL / INGLÉS

SpeechFormatter compone la frase. sherpa-onnx sintetiza en el teléfono.

La reproducción termina y la captura vuelve a estar disponible.

Informe, §§3.8–3.9 y figura 3.4

Interfaz, ajustes y accesibilidad





CONFIGURACIÓN

Idioma, velocidad, confianza, número de objetos y vista previa.

INTERACCIÓN

Controles identificables, avisos de estado y disparador físico compatible.

Informe, §§3.10–3.11. Capturas reales de la app en emulador

Verificación de los requerimientos

34

Pruebas JVM

Geometría, localización, texto, voz y controles.

5

Pruebas Android

Síntesis local y gestión de fotogramas en modo avión.

8

Pruebas del evaluador

Emparejamiento y estadística.

Informe, §§3.12–3.13; docs/VALIDACION.md

Demostración de AssistiveVision

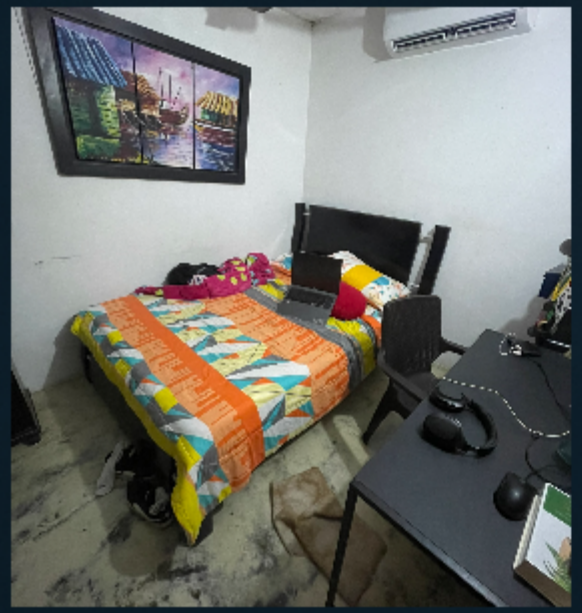
Capturar

Escuchar el objeto y su posición

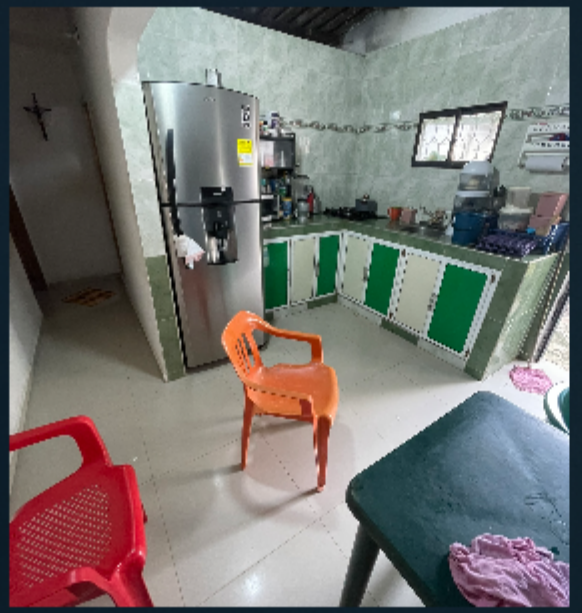
Cambiar el encuadre

Procesamiento y síntesis de voz locales

Diseño y espacios de captura



Dormitorio



Cocina



Baño

33 × 6

198 fotos
889 instancias
10 clases

30 recintos en 6 inmuebles

Soportes y campo visual



Cabeza



Pecho



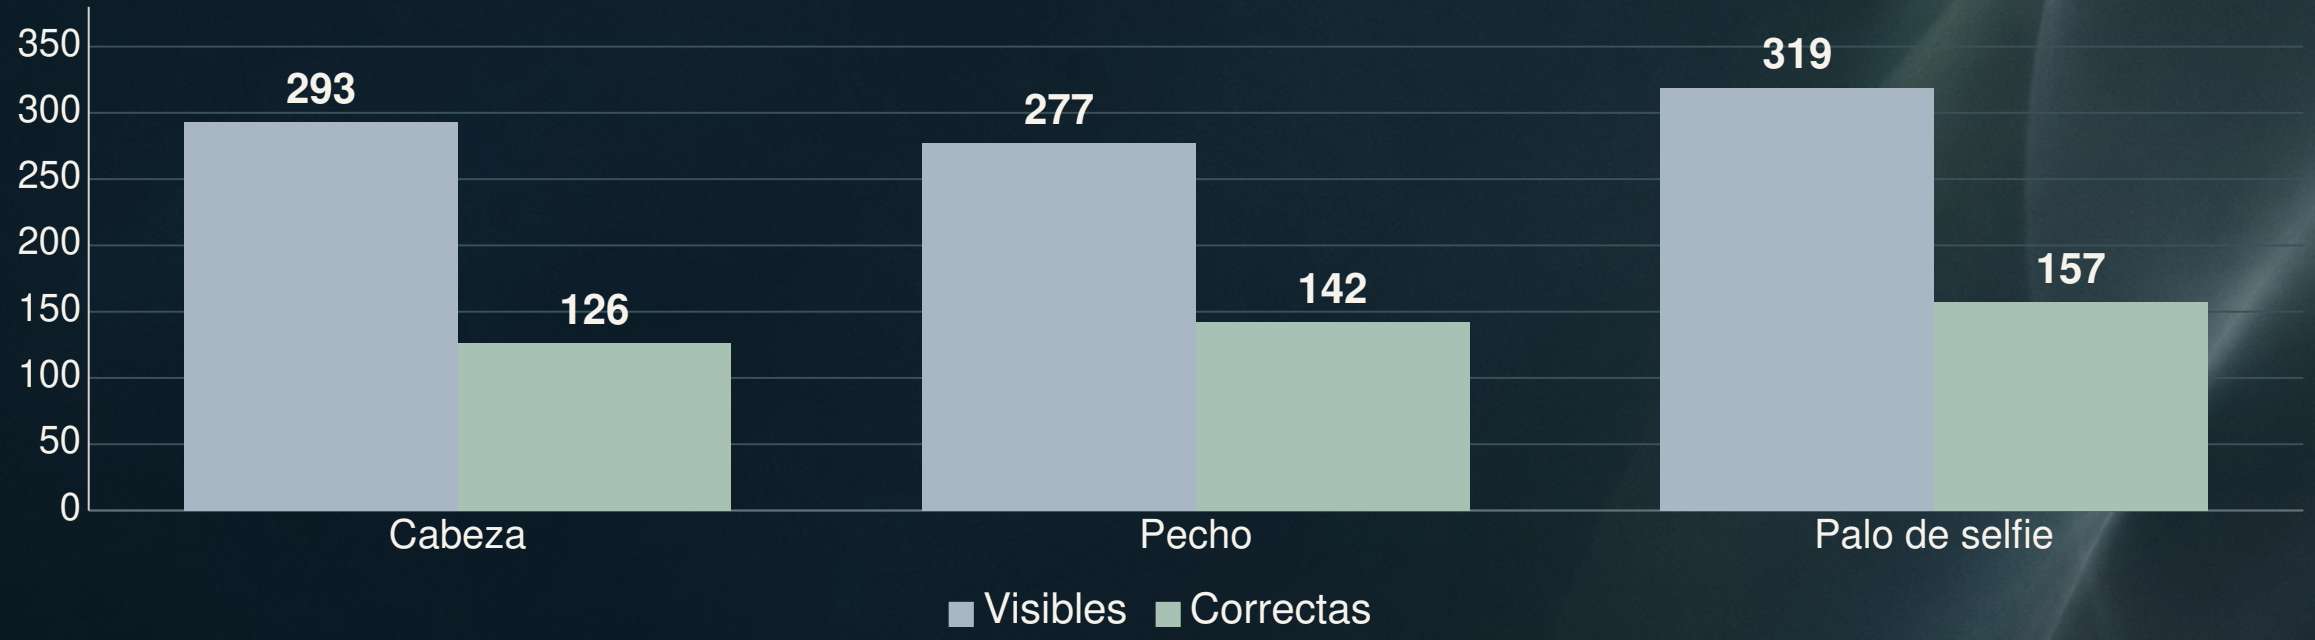
Palo de selfie

Cada soporte combina 1x y 0,5x nominales. 33 fotografías por configuración.

Informe, §§3.2, 4.1.2. Fotografías del autor

Comparación de montajes

Instancias visibles y detecciones correctas

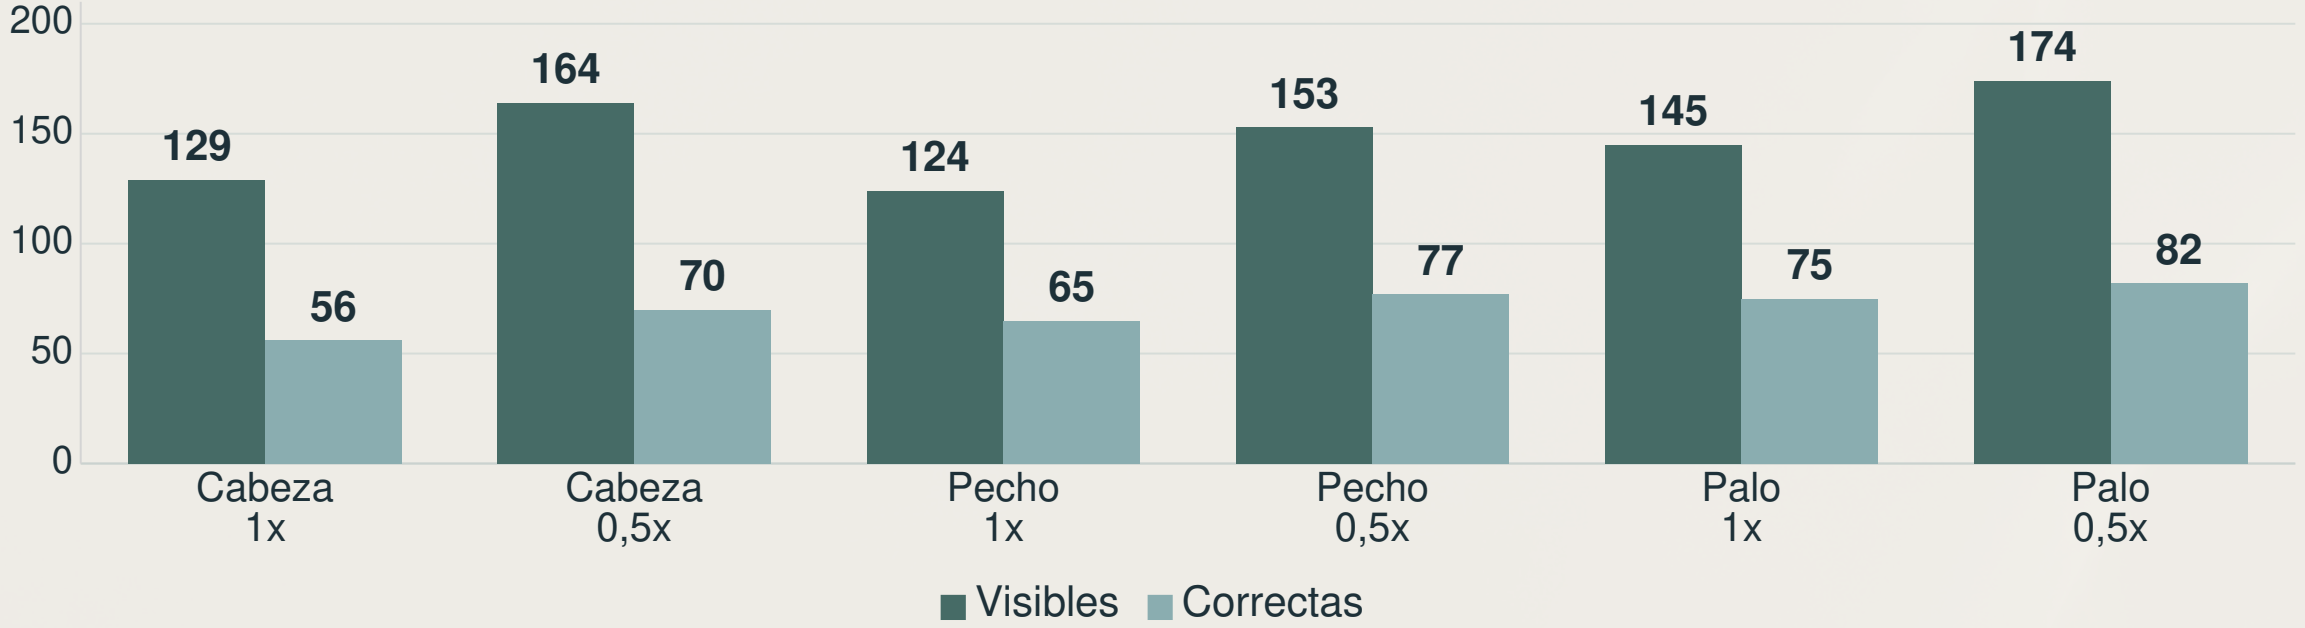


F1: 53,1 % cabeza · 60,2 % pecho · 58,6 % palo de selfie

Informe, §4.2; summary.csv, agregación por montaje

Las seis configuraciones de captura

Instancias por configuración



82 aciertos: palo 0,5x. Mayor F1: pecho 1x, 61,9 %.

Informe, §4.3; summary.csv, agregación por configuración

Comparaciones dentro del grupo

+17

detecciones correctas frente a pecho 1x

Palo de selfie 0,5x

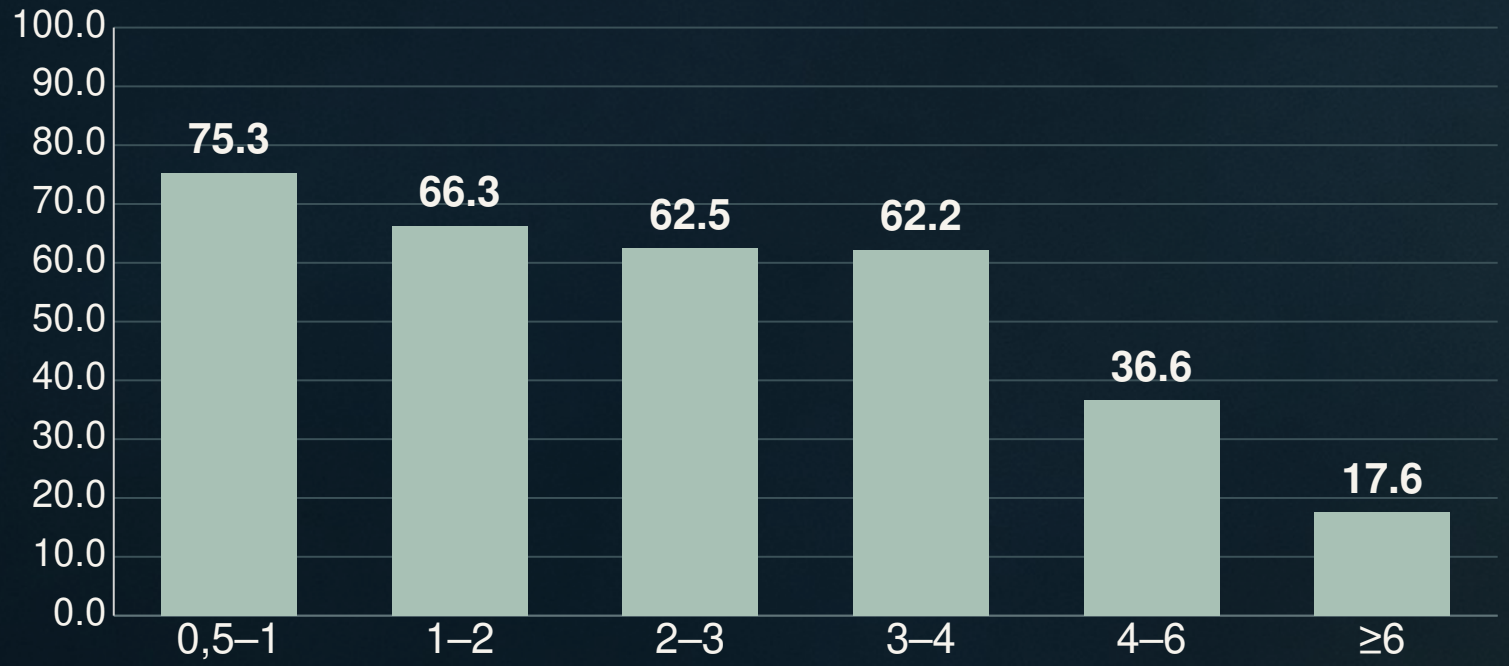
Alternativa	Δ por grupo	IC 95 %
Pecho 1x	+0,515	[0,121; 0,939]
Pecho 0,5x	+0,152	[–0,182; 0,515]
Palo 1x	+0,212	[–0,242; 0,667]

Los dos últimos intervalos incluyen cero.

Informe, §4.3; scenes/paired_count_differences.csv

Detección por distancia estimada

Recall (%) por banda de distancia estimada (m)

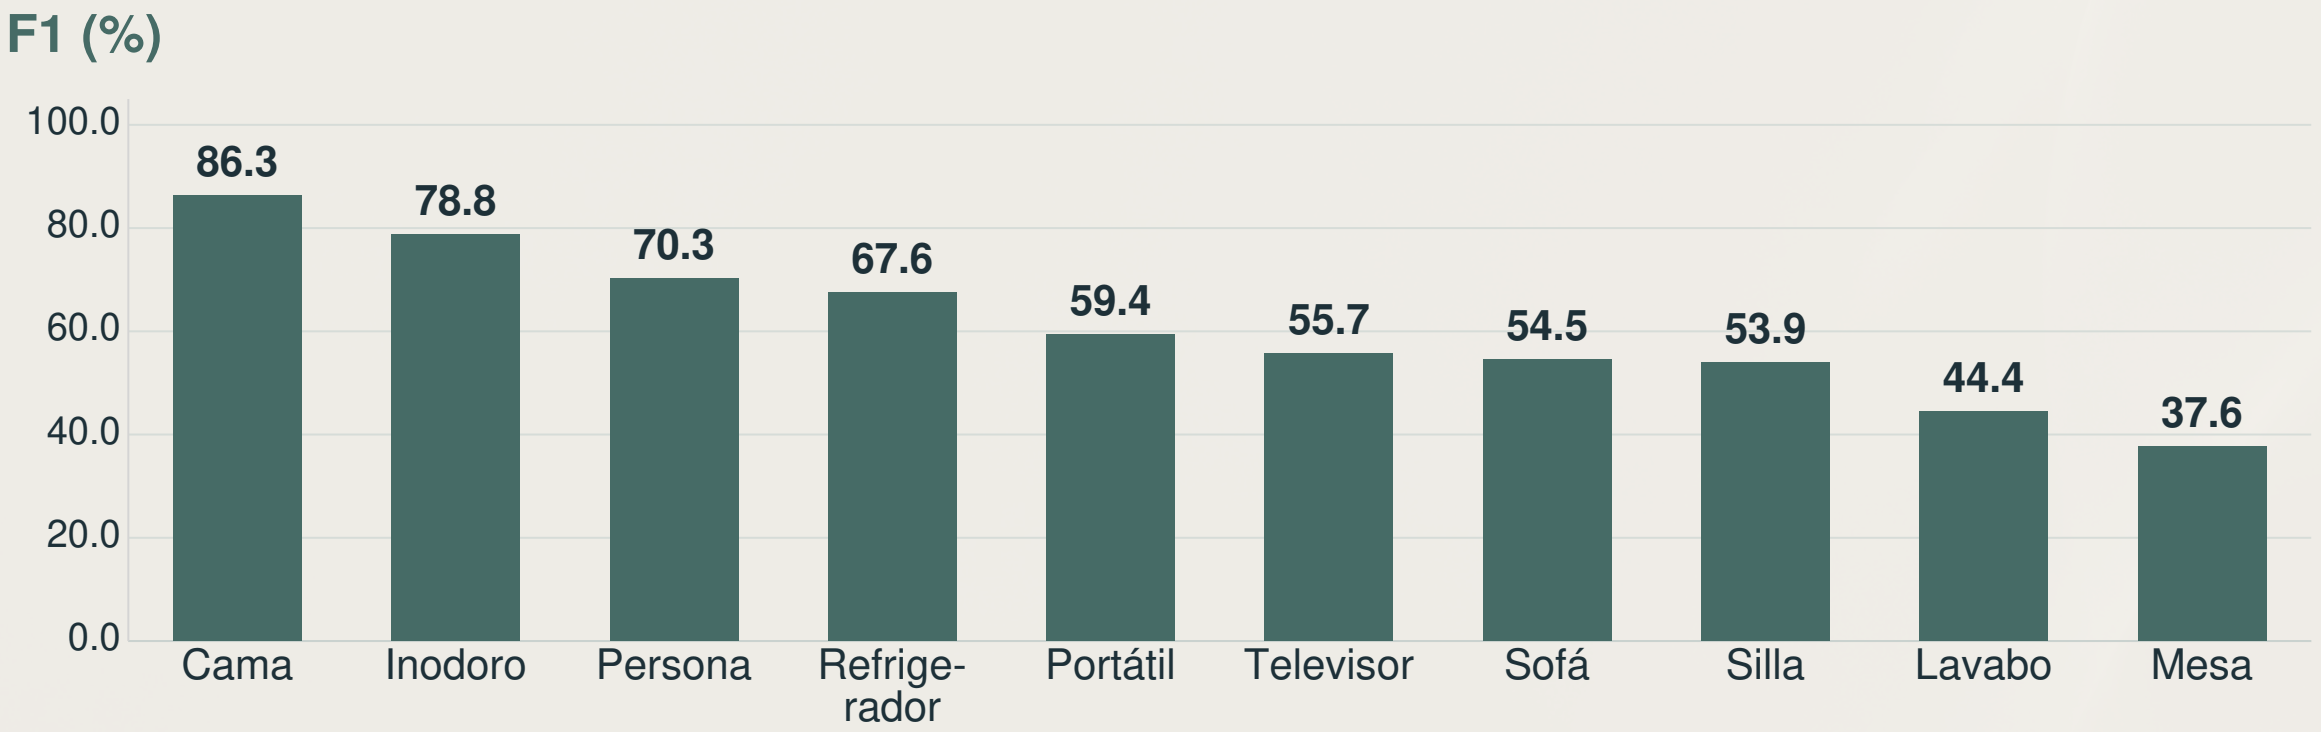


Banda (m)	IC 95 % del recall
0,5–1	57,0–94,1 %
1–2	54,7–78,4 %
2–3	50,0–73,4 %
3–4	45,9–76,2 %
4–6	25,0–48,1 %
≥6	7,9–21,4 %

Estimación sin calibración física. Cambia también la composición de objetos.

Informe, §4.4; depth/depth_bands.csv

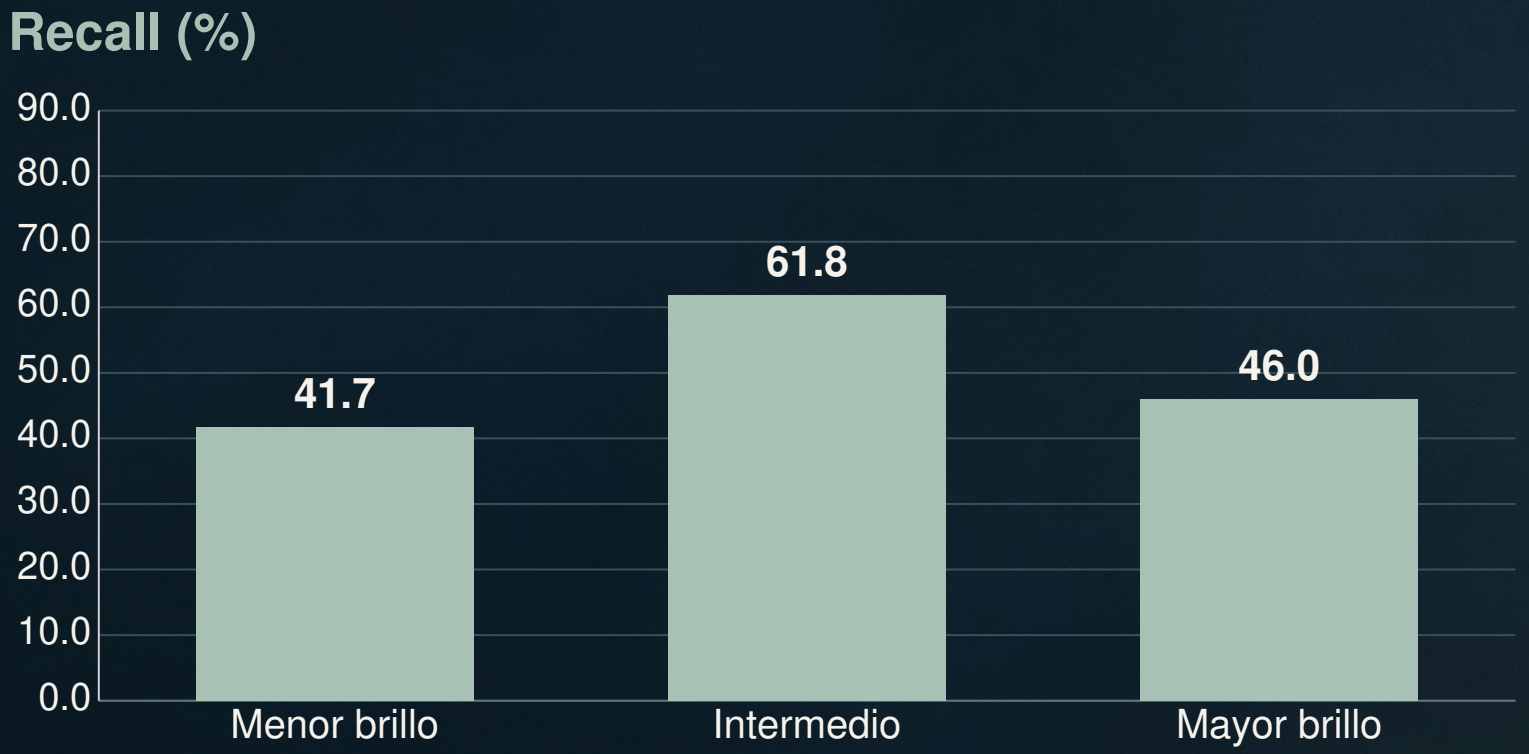
Desempeño por clase



438 de 889 anotaciones son sillas: 49,3 % del conjunto.

Informe, §4.5; per_class.csv, conteos agregados de las seis configuraciones

Brillo digital de las escenas



66

fotografías por grupo

Brillo de la imagen, sin medición en lux.

Informe, §4.8; results/brightness/summary.json

Oclusión observada



Etiquetas asistidas por IA. Revisión individual: 215 de 889 instancias.

39 instancias inciertas se analizan por separado.

Informe, §4.8.1; occlusion/results/severity.csv y uncertainty.csv

Distribución del procesamiento

352,4 ms

Mediana del procesamiento por imagen

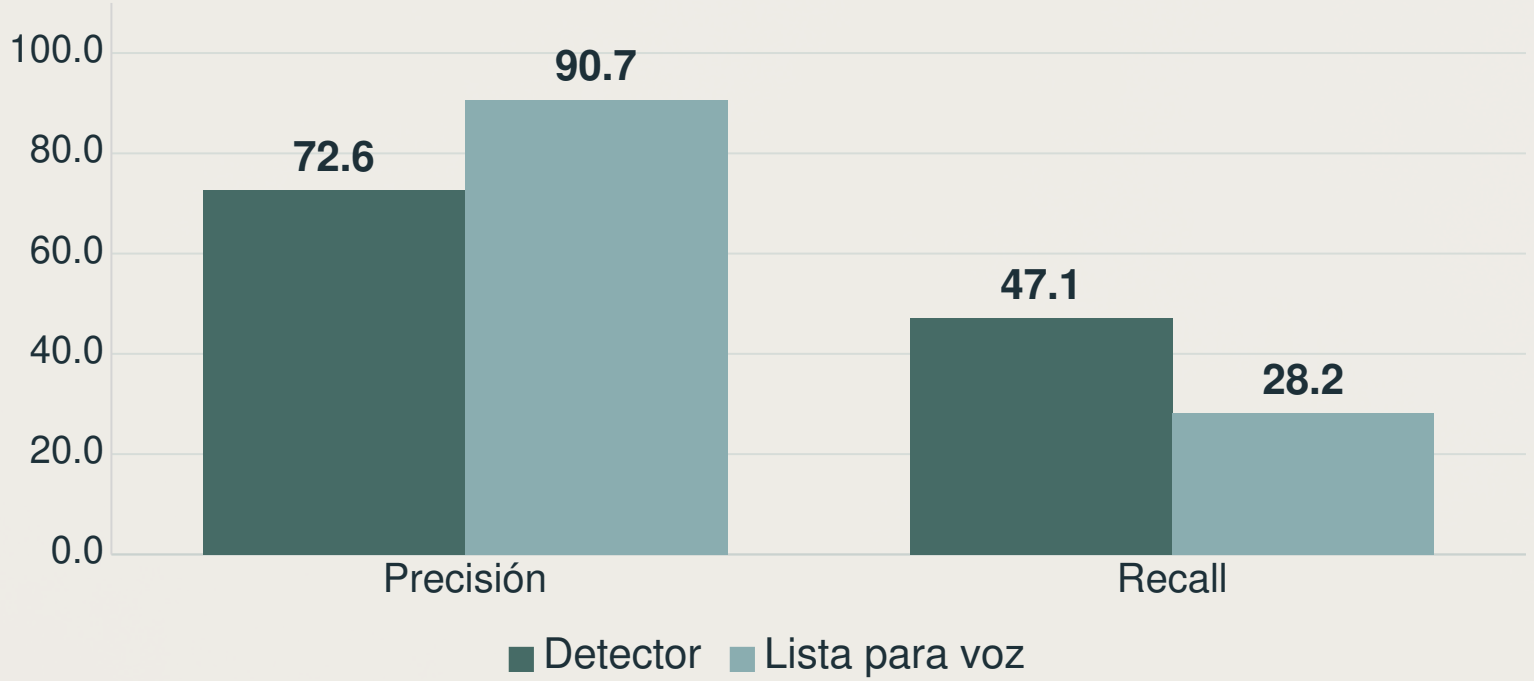
P95: 419,9 ms

Decodificación, preprocesamiento y detección. Audio fuera de esta medición.

Informe, §4.7; results/brightness/summary.json

Evaluación de la salida auditiva

Palo de selfie 0,5x · porcentajes



49 / 54

selecciones correctas para el anuncio

Formato bilingüe y síntesis local verificados.

Informe, §§4.5 y 4.9; summary.csv, palo de selfie 0,5x

Validez y continuidad del trabajo

CAPTURA Y GENERALIZACIÓN

Encuadres variables, lentes nominales y selección en el mismo conjunto.

MEDICIONES Y ANOTACIONES

Distancia estimada, brillo digital y oclusión con revisión parcial.

PRÓXIMA EVALUACIÓN CON USUARIOS

Comprensión, accesibilidad, ergonomía y tiempo completo hasta la voz.

Hallazgos frente a los objetivos

01 SELECCIÓN

EfficientDet-Lite2 equilibra exactitud, tiempo y memoria en el Redmi evaluado.

02 INTEGRACIÓN

Captura manual y descripción local de objetos y regiones, en español e inglés.

03 EVALUACIÓN

Más aciertos con palo 0,5x y mayor F1 con pecho 1x, según el criterio elegido.

Código, informe y reproducción

INDOOR-DETECT

Datos, anotaciones, resultados e informe final.

github.com/diomedescerda/indoor-detect

AssistiveVision · main

Aplicación Android, APK e instrucciones de compilación.

github.com/diomedescerda/AssistiveVision

Gracias

Preguntas y conversación

AssistiveVision / 2026

Comparación completa de modelos

Modelo	mAP50	mAP50–95	F1	CPU ms	GPU ms	RAM MB
YOLOv8s F32	0,642	0,514	0,702	620,8	743,8	164,1
YOLOv8s F16	0,642	0,514	0,702	622,1	741,1	150,8
YOLO11n F32	0,615	0,498	0,667	188,6	259,6	80,5
YOLO11n F16	0,614	0,498	0,662	198,1	256,6	79,8
SSD MobileNetV1	0,518	0,336	0,421	23,4	—	18,5
EfficientDet Lite2	0,648	0,486	0,695	124,9	357,9	65,8

Float32 / Float16 se abrevian F32 / F16. RAM corresponde a ejecución CPU.

Informe, tablas 2.1, 2.3 y 2.4; results/desktop.md y android.md

Seis configuraciones: métricas completas

Configuración	Visibles	TP	Precisión %	Recall %	F1 %
Cabeza 1x	129	56	73,7	43,4	54,6
Cabeza 0,5x	164	70	66,0	42,7	51,9
Pecho 1x	124	65	75,6	52,4	61,9
Pecho 0,5x	153	77	70,6	50,3	58,8
Palo 1x	145	75	72,1	51,7	60,2
Palo 0,5x	174	82	72,6	47,1	57,1

33 fotografías en cada combinación de soporte y lente nominal.

Informe, tabla 4.6; summary.csv, mode=detector

Notación y estimación geométrica

PRECISIÓN, RECALL Y F1

$P = TP / (TP + FP)$ $R = TP / (TP + FN)$ $F1 = 2PR / (P + R)$

DISTANCIA ESTIMADA

$d \approx f_{px} \times Hclase / hcaja$ Focal, altura de referencia y altura de la caja.

COORDENADAS DE LA ZONA

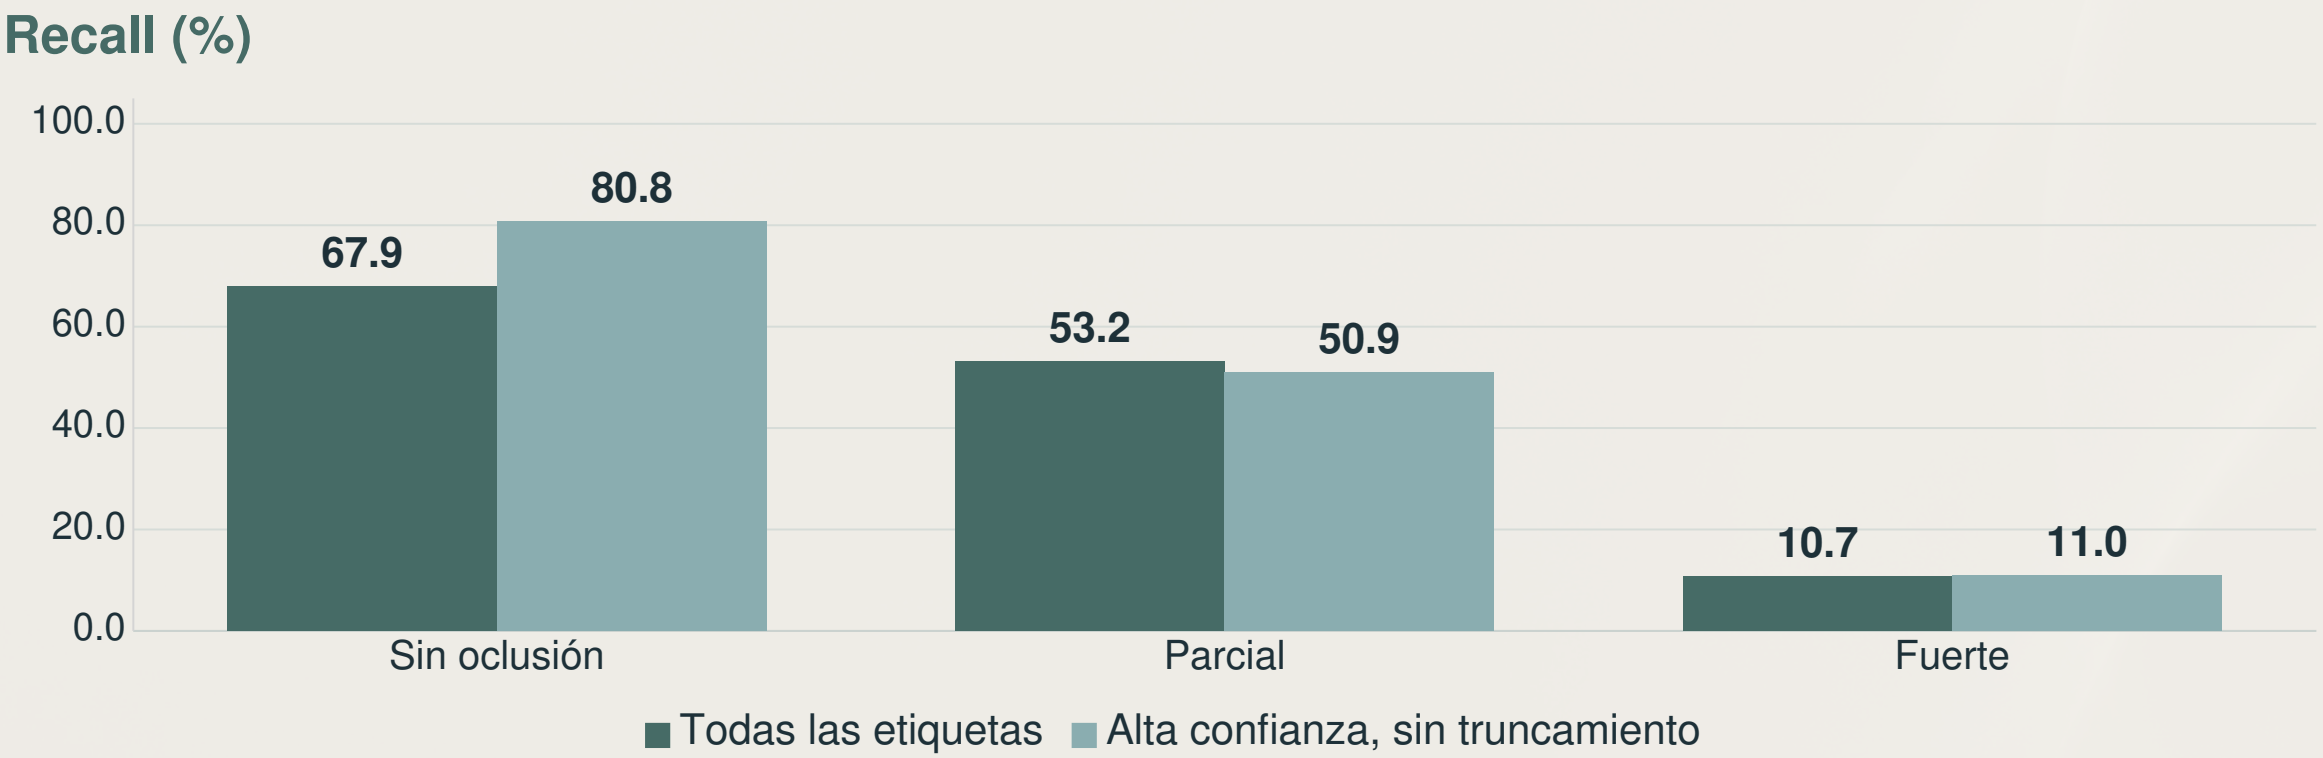
$u = cx / W$ $v = cy / H$ Cortes: 0,35 / 0,65 y 0,50.

Exactitud de las diez clases

Clase	Anotaciones	TP	Precisión %	Recall %	F1 %
Cama	56	44	95,7	78,6	86,3
Inodoro	38	26	92,9	68,4	78,8
Persona	56	39	70,9	69,6	70,3
Refrigerador	43	24	85,7	55,8	67,6
Computador portátil	34	19	63,3	55,9	59,4
Televisor	50	27	57,4	54,0	55,7
Sofá	11	6	54,5	54,5	54,5
Silla	438	194	68,8	44,3	53,9
Lavamanos	56	18	72,0	32,1	44,4
Mesa de comedor	107	28	66,7	26,2	37,6

Informe, tabla 4.9; per_class.csv, suma de conteos por categoría

Oclusión: análisis de sensibilidad



Sillas medianas: recall 75,0 / 62,0 / 27,3 %; grupos de 72 / 100 / 22 instancias.

Informe, §4.8.1; occlusion/results/sensitivity.csv y by_class_area.csv

Parámetros y operación

Parámetro	Configuración
Idioma	Español / inglés
Velocidad de habla	0,5×–2,5× · predeterminado 1,0×
Confianza	0,10–0,90 · predeterminado 0,30
Máximo de objetos	1, 2 o 3 · predeterminado 2
Vista previa	Visible u oculta
Captura	Manual · liberación al terminar la voz o al fallar

Prueba en vivo: confirmar volumen, permiso de cámara y vocabulario soportado.

Referencias y materiales

Asistencia visual

Meenakshi et al. (2022)
Guravaiah et al. (2023)
Pawar (2025, preprint)
Figura et al. (2025)
More et al. (2025)

Detección y ejecución

Lin et al. (2014): COCO
Ren et al. (2015): Faster R-CNN
Liu et al. (2016): SSD
Tan et al. (2020): EfficientDet
Google: CameraX y LiteRT

Datos, código y versiones: github.com/diomedescerda/indoor-detect