PRESENTADO POR DIOMEDES CERDA

UNIVERSIDAD DEL MAGDALENA

Deteccion de objetos panoramicos

Como la geometria equirectangular cambia lo que los detectores ven, puntuan y seleccionan.

RESUMEN DEL BENCHMARK

YOLOv8s · YOLO11n · SSD · EfficientDet
TensorFlow Lite / solo CPU



Comparación

Dataset y superficie de evaluacion

57	505	10	6	TFLite
IMAGENES PANORAMICAS	ANOTACIONES	CLASES INTERIORES	MODELOS	EJECUCION
				Solo CPU

Clases mapeadas a IDs COCO

01 person	02 chair	03 couch	04 bed	05 dining table
06 toilet	07 tv	08 laptop	09 sink	10 refrigerator

Evaluacion

COCO mAP50 · mAP50-95 · precision · recall · F1

Se usaron el mismo postprocesamiento y umbrales
para aislar el efecto de la geometria de entrada.

Que cambiamos

Un benchmark configurable permite ejecutar el mismo proceso de inferencia sobre dos mundos visuales.

MODO NORMAL

`test_images/data/`

- Fotografias en perspectiva
- Geometria de imagen estandar
- Resultados: results/desktop.md

MODO PANORAMICO

`panoramic/data/`

- Panoramas equirectangulares
- Campo de vision amplio + distorsion
- Resultados: results/panoramic_desktop.md

`benchmark_config.json`

El problema geometrico

Una escena de 360 grados se despliega sobre un rectangulo plano.
El modelo recibe pixeles, no coordenadas esfericas.



- La escala horizontal cambia con la latitud
- Las lineas rectas pueden curvarse o estirarse
- Un objeto puede adoptar formas muy distintas
- Los patrones aprendidos son menos fiables

De los pixeles a la decision

01
cargar
imagen JPEG

>

02
letterbox
640 × 640

>

03
inferir
TFLite

>

04
filtrar
confianza

>

05
NMS
cajas finales

EFECTO PANORAMICO

La distorsion aparece antes de la inferencia. Una vez aplicado el letterbox, la red interpreta evidencia estirada usando patrones de imagen en perspectiva.

Que recibe realmente el modelo

Este ejemplo corresponde al preprocesamiento de YOLOv8s y YOLO11n: la imagen se centra en un lienzo de 640 × 640 pixeles.

IMAGEN PANORAMICA ORIGINAL



ENTRADA YOLO: 640 × 640



El area gris es padding. EfficientDet-Lite2 usa 448 × 448 y SSD MobileNetV1 usa 300 × 300.

Impacto medido: normal vs panoramico

El mAP50 baja para todos los modelos en el benchmark panoramico.

MODELO	NORMAL	PANORAMICO	CAMBIO	CAMBIO EN RECALL
YOLOv8s	0.642	0.499	-0.143	-0.220
YOLO11n	0.615	0.402	-0.213	-0.304
SSD MobileNet	0.518	0.100	-0.418	-0.430
EfficientDet	0.648	0.269	-0.379	-0.457

Mejor mAP50 panoramico: YOLOv8s con 0.499

Mayor caida de mAP50: EfficientDet-Lite2 (−0.379)

Como la distorsion cambia las decisiones

CONFIANZA

La evidencia visual es mas debil

El estiramiento cambia textura, bordes y proporciones. Los scores bajan o son menos estables.

LOCALIZACION

Las cajas encajan peor

Un detector entrenado con rectangulos normales ve formas desconocidas y aumenta el error de IoU.

RECALL

Se pierden mas objetos

La caida medida del recall muestra que el modelo se vuelve conservador ante objetos distorsionados.

CLASIFICACION

Las clases similares compiten

Las pistas de silla, sofa o mesa pueden deformarse y cambiar la clase ganadora.

Patron observado: la precision se mantiene relativamente alta en YOLO, mientras que el recall absorbe la mayor parte de la penalizacion panoramica.

La senal mas afectada es el recall

Comparacion de recall



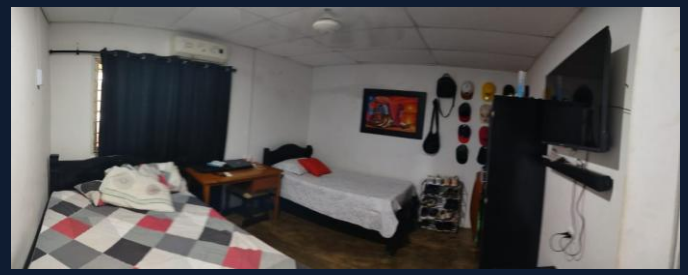
Lectura

YOLOv8s es la linea base mas resistente

- Recall panoramico: 0.453
- mAP50 panoramico: 0.499
- Float16 ≈ Float32 en precision

Esto sugiere que el cuello de botella es la representacion, no la cuantizacion.

Lo que el modelo debe interpretar



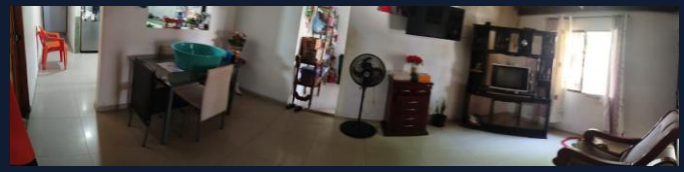
Contexto de escena amplia

entrada equirectangular



Contexto de escena amplia

entrada equirectangular



Contexto de escena amplia

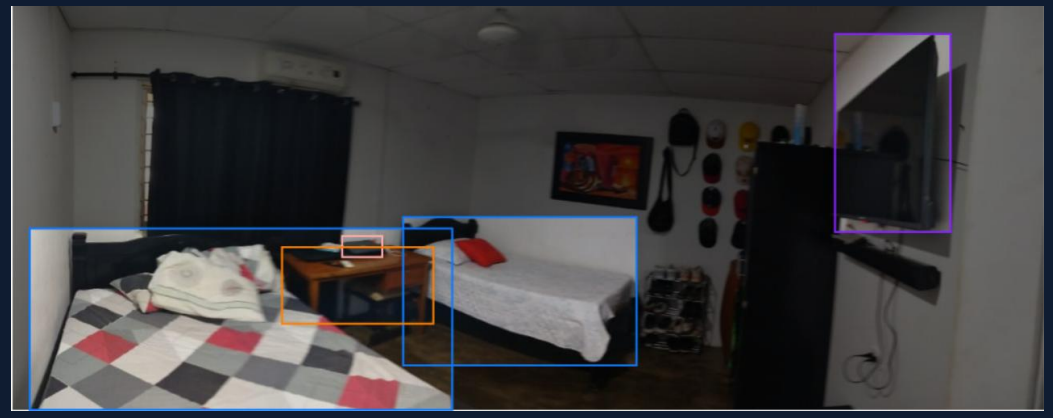
entrada equirectangular

La misma clase puede verse compacta en una region y estirada en otra.

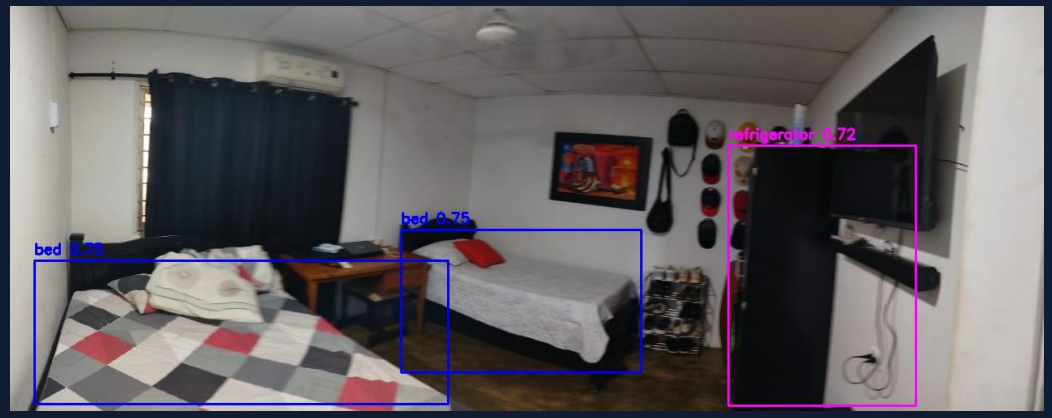
Imagen original frente a detecciones

La visualizacion permite observar como el modelo convierte la escena panoramica en decisiones concretas: clase, caja y confianza.

ORIGINAL



CON CAJAS PREDICHAS

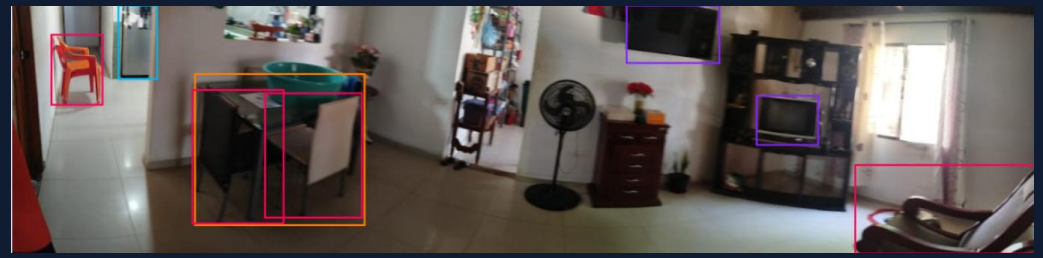


YOLO11n Float16 · umbral de confianza aplicado · salida sobre la misma imagen

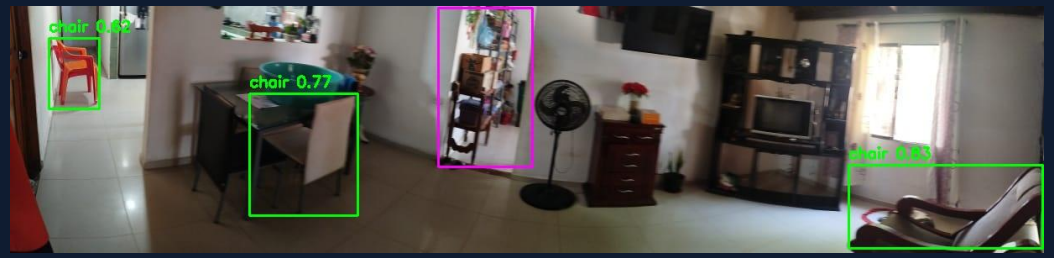
Imagen original frente a detecciones

La visualizacion permite observar como el modelo convierte la escena panoramica en decisiones concretas: clase, caja y confianza.

ORIGINAL



CON CAJAS PREDICHAS



YOLO11n Float16 · umbral de confianza aplicado · salida sobre la misma imagen

Conclusiones

La deteccion panoramica no es solo un problema de imagen mas grande.
Es un cambio de dominio causado por la geometria.

01

YOLOv8s es el mejor punto de partida

mAP50 0.499 y F1 0.561
en el conjunto panoramico.

02

El recall es la senal de alerta

Los modelos pierden mas objetos
aunque la precision siga competitiva.

03

Float16 no es el problema principal

La precision casi no cambia
entre Float32 y Float16.

MODELO SELECCIONADO: EFFICIENTDET-LITE2 · MODO NORMAL